


## การเรียนรู้ของเครือข่ายเพอร์เซ็ปตรอน Perceptron Learning

Warren McCulloch และ Walter Pitts [McCulloch and Pitts, 1943] ได้นำเสนอแบบจำลองนิวรอนรุ่นแรกในปี 1943 โดยมีหลักการง่ายในการรวมอินพุตพร้อมทั้งค่าน้ำหนักประสาท แล้วนำไปเปรียบเทียบกับค่าจุดเปลี่ยนระดับ (thresholding) ซึ่งถ้าผลรวมมีค่ามากกว่าจุดเปลี่ยนระดับ เอาต์พุตของนิวรอนจะให้ค่าเป็น 1 ถ้าผลรวมมีค่าไม่ถึงจุดเปลี่ยนระดับ เอาต์พุตของนิวรอนจะมีค่า 0 ในการนำเสนอได้มีการแสดงถึงความสามารถในการคำนวณทางคณิตศาสตร์ได้ ในการนำเสนอไม่ได้กล่าวถึงการเรียนรู้ของเครือข่าย ค่าพารามิเตอร์ต่างๆ ถูกกำหนดขึ้นเอง อย่างไรก็ตามโครงสร้างที่ได้นี้เป็นเพียงการเชื่อมโยงระหว่างระบบประสาทของมนุษย์ กับแบบจำลองประสาทที่ได้รับการพัฒนาต่อมาจนกระทั่งถึงปัจจุบัน

ต่อมาในช่วงปลายศตวรรษที่ 1950 Frank Rosenblatt [Rosenblatt, 1960, 1962, 1958] และนักวิจัยค้นคว้าอีกมากมายได้พัฒนาเครือข่ายประสาทเทียมเรียกว่าเพอร์เซ็ปตรอน (perceptron) ซึ่งมีโครงสร้างที่คล้ายคลึงกับแบบจำลองของ McCulloch และ Pitts โดยได้นำเสนอถึงวิธีการเรียนรู้ของเครือข่าย ในการนำไปประยุกต์แก้ปัญหาทางด้านการจดจำรูปแบบ (pattern recognition) Rosenblatt ได้พิสูจน์ว่ากฎการเรียนรู้ที่ได้นำเสนอนั้นจะเข้าสู่ค่าน้ำหนักประสาทของเครือข่ายได้อย่างถูกต้องเสมอ (นั่นคือสามารถฝึกสอนเครือข่ายจนกระทั่งเรียนรู้และใช้งานได้) การเรียนรู้ของเครือข่ายไม่มีความซับซ้อนและเป็นไปอย่างอัตโนมัติ นอกจากนั้นยังได้แสดงถึงตัวอย่างพฤติกรรมของระบบของเครือข่าย ที่สามารถเรียนรู้จากข้อผิดพลาดของตัวเองได้ เพอร์เซ็ปตรอนที่ได้นำเสนอยังมีความสามารถในการเรียนรู้ ถึงแม้ว่าค่าน้ำหนักประสาทและไบอัสในสภาวะเริ่มต้นจะเป็นค่าจากการสุ่ม

อย่างไรก็ตาม ตัวเพอร์เซ็ปตรอนนั้นก็มีข้อจำกัดอยู่หลายๆ ด้าน ซึ่งในเวลาต่อมาได้มีการพัฒนาโครงสร้างรูปแบบของเพอร์เซ็ปตรอน เพื่อแก้ไขข้อจำกัดต่างๆ เหล่านั้น เครือข่ายเพอร์เซ็ปตรอนยังคงมีความสำคัญและถูกนำมาใช้งานจนกระทั่งถึง ณ ปัจจุบัน ซึ่งถือเป็นเครือข่ายที่มีความเร็วสูงและมีความน่าเชื่อถือ (reliable) ในระดับของงานที่พิสูจน์แล้วว่าเพอร์เซ็ปตรอนสามารถรองรับได้ เนื่องจากเครือข่ายเพอร์เซ็ปตรอนไม่มีโครงสร้างที่ซับซ้อน รวมไปถึงกฎการเรียนรู้ที่ง่ายและตรงไปตรงมา จึงเป็นจุดเริ่มต้นที่ดีในการศึกษาในด้านพื้นฐานเกี่ยวกับเครือข่ายประสาทเทียมต่อไป

เนื้อหาในบทนี้จะได้กล่าวถึงสถาปัตยกรรมของเพอร์เซ็ปตรอน และกฎการเรียนรู้แบบเพอร์เซ็ปตรอน รวมไปถึงตัวอย่างการปรับแต่งกฎในรูปแบบต่างๆ เพื่อให้ได้การเรียนรู้ที่มีประสิทธิภาพมากขึ้น



รูปที่ 9.1: เครือข่ายเพอร์เซ็ปตรอน

## 9.1 สถาปัตยกรรมของเพอร์เซ็ปตรอน

โครงสร้างทั่วไปของเพอร์เซ็ปตรอนมีแสดงในรูปที่ 9.1 เอาต์พุตของเครือข่ายคือ

$$y = \text{hardlim}(Wp + b) \quad (9.1)$$

เมื่อพิจารณารายละเอียดของเครือข่ายเพอร์เซ็ปตรอนดังกล่าว จะเห็นว่าเครือข่ายเพอร์เซ็ปตรอนคือเครือข่ายแบบไปข้างหน้า (feedforward network) ที่มีจำนวนชั้นของนิวรอนเพียง 1 ชั้น มีจำนวนนิวรอนเท่ากับ  $S$  และฟังก์ชันถ่ายโอนเป็นแบบฮาร์ดลิมิต (เอาต์พุตมีค่าเป็น 0 หรือ 1) อินพุตของเครือข่ายมีจำนวนเท่ากับ  $R$  และมีจำนวนไบอัสของแต่ละนิวรอนรวมแล้วเท่ากับ  $S$  ในเนื้อหาถัดไป ผู้อ่านจะได้วิเคราะห์ในเรื่องข้อจำกัดของเครือข่ายที่มีสถาปัตยกรรมของนิวรอนเพียง 1 ชั้นนี้

พิจารณาเมตริกซ์น้ำหนักประสาท

$$W = \begin{bmatrix} w_{11} & w_{12} & \cdots & w_{1R} \\ w_{21} & w_{22} & \cdots & w_{2R} \\ \vdots & \vdots & \ddots & \vdots \\ w_{S1} & w_{S2} & \cdots & w_{SR} \end{bmatrix} \quad (9.2)$$

เพื่อความสะดวกในบางครั้ง เราจะเขียนแยกให้อยู่ในรูปเมตริกซ์แถวที่  $i$  ของ  $W$  คือ

$${}_iW = [w_{i1} \quad w_{i2} \quad \cdots \quad w_{iR}] \quad (9.3)$$


ดังนั้นสามารถเขียนเมตริกซ์น้ำหนักประสาท  $W$  ในรูปของเมตริกซ์แถว  ${}_iW$  ได้ดังนี้

$$W = \begin{bmatrix} {}_1W \\ {}_2W \\ \vdots \\ {}_SW \end{bmatrix} \quad (9.4)$$


เราสามารถเขียนเอาต์พุตของเครือข่ายแยกเป็นองค์ประกอบย่อยตามเมตริกซ์แถวที่  $i$  ได้คือ

$$y_i = \text{hardlim}(n_i) = \text{hardlim}({}_iWp + b_i) \quad (9.5)$$

จะได้ว่าถ้าผลคูณภายใน (inner product) ของเมตริกซ์น้ำหนักประสาทแถวที่  $i$  กับเวกเตอร์ของอินพุตมากกว่าหรือเท่ากับ  $-b_i$  แล้ว เอาต์พุตของเครือข่ายจะมีค่าเป็น 1 ถ้าค่าผลคูณภายในเป็นนอกเหนือจากนี้แล้ว เอาต์พุตของเครือข่ายจะเป็น 0 ผลสรุปที่สำคัญ ณ จุดนี้คือ นิวรอนแต่ละตัวในเครือข่ายจะทำการแบ่งพื้นที่ของอินพุต (input space) ออกเป็นสองพื้นที่ ในหัวข้อต่อไปจะทำการศึกษาเกี่ยวกับเส้นแบ่งพื้นที่ดังกล่าว โดยจะพิจารณาในกรณีของเครือข่ายที่มีนิวรอนตัวเดียวและมี 2 อินพุต



รูปที่ 9.2: เพอร์เซ็ปตรอนนิวรอนเดี่ยวแบบ 2 อินพุต



รูปที่ 9.3: ตัวอย่างเส้นแบ่งพื้นที่ในกรณี  ${}_1\mathbf{w} = [1 \ 1]$

### 9.1.1 เพอร์เซ็ปตรอนแบบนิวรอนเดี่ยว Single-Neuron Perceptron

พิจารณาโครงสร้างของเพอร์เซ็ปตรอนที่มีเพียงนิวรอนเดี่ยวในรูปที่ 9.2 เอาต์พุตของเครือข่ายสามารถเขียนได้ดังนี้ (พิจารณาใช้สัญลักษณ์  ${}_1\mathbf{w}$  แทนเวกเตอร์น้ำหนักประสาทแฉงที่ 1 ของเครือข่ายเพอร์เซ็ปตรอนที่มี 1 นิวรอน)

$$\begin{aligned} y &= \text{hardlim}(n) = \text{hardlim}(\mathbf{W}\mathbf{p} + b) \\ &= \text{hardlim}({}_1\mathbf{w}\mathbf{p} + b) \\ &= \text{hardlim}(w_{11}p_1 + w_{12}p_2 + b) \end{aligned} \quad (9.6)$$

ความสัมพันธ์ข้างต้นสามารถพิจารณาเป็นการแบ่งพื้นที่ของอินพุต  $(p_1, p_2)$  ออกเป็น 2 พื้นที่ได้ด้วยเส้นแบ่งพื้นที่ (decision boundary) โดยพิจารณาจากความสัมพันธ์ของเอาต์พุต  $n$  มีค่าเท่ากับศูนย์ดังนี้

$$n = {}_1\mathbf{w}\mathbf{p} + b = w_{11}p_1 + w_{12}p_2 + b = 0 \quad (9.7)$$


พิจารณาแทนค่าน้ำหนักประสาทและไบอัสด้วย  $w_{11} = 1$   $w_{12} = 1$  และ  $b = -1$  จะได้เส้นแบ่งพื้นที่คือ

$$n = {}_1\mathbf{w}\mathbf{p} + b = w_{11}p_1 + w_{12}p_2 + b = p_1 + p_2 - 1 = 0 \quad (9.8)$$


รูปที่ 9.3 แสดงเส้นแบ่งพื้นที่ โดยพื้นที่ตั้งแต่เส้นตรงและส่วนแรงงขึ้นไปเป็นส่วนที่  $n \geq 0$  ซึ่งให้ค่าเอาต์พุตของเครือข่ายเป็น  $y = 1$  สังเกตว่าเส้นแบ่งพื้นที่จะตั้งฉากกับ  ${}_1\mathbf{w}$  เสมอดังตัวอย่างแสดงในรูปที่ 9.4  ${}_1\mathbf{w}$  จะชี้ไปในทิศทางของพื้นที่ที่ซึ่งเอาต์พุต  $y$  ของนิวรอนมีค่าเป็น 1 เส้นแบ่งพื้นที่สามารถนิยามได้ดังนี้

$${}_1\mathbf{w}\mathbf{p} + b = 0 \quad (9.9)$$

นิวรอนที่ใช้ในการแบ่งพื้นที่ข้างต้น สามารถแบ่งพื้นที่ออกเป็นสองส่วน ในกรณีของเพอร์เซ็ปตรอนที่มีหลายนิวรอน เส้นแบ่งพื้นที่ดังกล่าวจะมีจำนวนเท่ากับจำนวนนิวรอนด้วย ความสามารถในการแบ่งพื้นที่ปริภูมิอินพุตได้



รูปที่ 9.4: เส้นแบ่งพื้นที่ตั้งฉากกับเมตริกซ์น้ำหนักประสาทเสมอ



รูปที่ 9.5: เพอร์เซ็ปตรอนแบบหลายนิวรอน

หลายๆ พื้นที่ที่มีความจำเป็นต่อปัญหาที่มีความซับซ้อนมากขึ้นในหลายๆ กรณี โดยเฉพาะงานทางด้านการจำแนกหรือจัดจำรูปแบบ นิวรอนที่กล่าวถึงในหัวข้อข้างต้น เป็นนิวรอนที่มี 2 อินพุต การแสดงการแบ่งพื้นที่ที่สามารถแสดงได้ด้วยรูป 2 มิติ ในทางปฏิบัติแล้ว จำนวนอินพุตที่ใช้งานจริงจะมากกว่า 2 การแสดงผลของตัวแปรมากกว่า 2 นั้นไม่สะดวก เนื้อหาในบทนี้จะใช้นิวรอนขนาด 2 อินพุตในการแสดงผล รายละเอียดของเพอร์เซ็ปตรอนแบบหลายนิวรอนจะได้กล่าวถึงในหัวข้อต่อไป

### 9.1.2 เพอร์เซ็ปตรอนแบบหลายนิวรอน Multiple-Neuron Perceptron

สำหรับเพอร์เซ็ปตรอนแบบหลายนิวรอนดังแสดงในรูปที่ 9.5 แต่ละนิวรอนจะมีเส้นแบ่งพื้นที่ โดยเส้นแบ่งพื้นที่ของนิวรอนตัวที่  $i$  คือ

$$i\mathbf{w}\mathbf{p} + b_i = 0 \quad (9.10)$$

เพอร์เซ็ปตรอนแบบนิรอนเดี่ยวสามารถตัดแยกอินพุตเวกเตอร์ออกเป็นสองกลุ่ม ที่มีเอาต์พุตค่าเป็น 0 และ 1 ดังนั้นเพอร์เซ็ปตรอนแบบหลายนิรอนจะสามารถตัดแยกอินพุตออกเป็นหลายๆ กลุ่มได้ แต่ละกลุ่มมีเอาต์พุตเวกเตอร์ที่ต่างกัน จำนวนกลุ่มที่เพอร์เซ็ปตรอน  $S$  นิรอนสามารถตัดแยกได้คือ  $2^S$  (แต่นิรอนสามารถแบ่งพื้นที่ได้ 2 ส่วน)

## 9.2 กฎการเรียนรู้แบบเพอร์เซ็ปตรอน Perceptron Learning Rule

ในการออกแบบเครือข่ายเพอร์เซ็ปตรอน สิ่งที่ต้องทำการคำนวณหาคือค่าของเมตริกซ์น้ำหนักประสาทโดยใช้กฎการเรียนรู้แบบเพอร์เซ็ปตรอน ซึ่งเป็นการเรียนรู้แบบมีผู้ฝึกสอน(supervised learning) โดยการนำเสนอคู่อินพุตและเป้าหมายที่ต้องการให้กับเครือข่าย

$$\{p_1, t_1\} \{p_2, t_2\} \dots \{p_Q, t_Q\} \quad (9.11)$$

โดยที่  $p_i$  เป็นอินพุตตัวที่  $i$  และ  $t_i$  เป็นคูเป้าหมายของอินพุต  $i$  นั้นๆ อินพุต  $p_i$  แต่ละตัวจะถูกป้อนให้กับเครือข่าย แล้วเอาต์พุต  $y$  ที่ได้จะถูกนำไปเปรียบเทียบกับเป้าหมาย  $t_i$  เครือข่ายจะทำการปรับค่าน้ำหนักประสาทและไบอัสตามกฎการเรียนรู้ เพื่อให้เอาต์พุตของเครือข่ายถูกปรับให้เข้าใกล้เป้าหมายมากที่สุด กฎการเรียนรู้แบบเพอร์เซ็ปตรอนมีดังนี้ (สัญลักษณ์  ${}_1w$  คือเวกเตอร์แถวที่ 1 ของเมตริกซ์น้ำหนักประสาท ซึ่งใช้แทนเครือข่ายเพอร์เซ็ปตรอนที่มี 1 นิรอน)

### ▷ กฎการเรียนรู้ของเพอร์เซ็ปตรอน - I

$$\begin{array}{ll} \text{ถ้า } t = 1 \text{ และ } y = 0 & \text{แล้ว } {}_1w^{new} = {}_1w^{old} + p \\ \text{ถ้า } t = 0 \text{ และ } y = 1 & \text{แล้ว } {}_1w^{new} = {}_1w^{old} - p \\ \text{ถ้า } t = y & \text{แล้ว } {}_1w^{new} = {}_1w^{old} \end{array} \quad (9.12)$$

กฎการเรียนรู้ข้างต้นสามารถเขียนให้อยู่ในรูปทั่วไปได้ โดยกำหนดให้ค่าความผิดพลาด (error) ของเครือข่ายเพอร์เซ็ปตรอนคือ  $e = t - y$  จะได้ว่า

### ▷ กฎการเรียนรู้ของเพอร์เซ็ปตรอน - II

$$\begin{array}{ll} \text{ถ้า } e = 1 & \text{แล้ว } {}_1w^{new} = {}_1w^{old} + p \\ \text{ถ้า } e = -1 & \text{แล้ว } {}_1w^{new} = {}_1w^{old} - p \\ \text{ถ้า } e = 0 & \text{แล้ว } {}_1w^{new} = {}_1w^{old} \end{array} \quad (9.13)$$

หรือเขียนให้อยู่ในรูปความสัมพันธ์เดียวได้คือ

$${}_1w^{new} = {}_1w^{old} + ep \quad (9.14)$$

$$= {}_1w^{old} + (t - y)p \quad (9.15)$$

สำหรับไบอัสจะใช้กฎการเรียนรู้เดียวกันกล่าวคือ

$$b^{new} = b^{old} + e \quad (9.16)$$

เช่นเดียวกันกับเครือข่ายเพอร์เซ็ปตรอนแบบนิวรอนเดียว กฎการเรียนรู้แบบเพอร์เซ็ปตรอนในการปรับค่าเมตริกซ์น้ำหนักประสาทแฉที่  $i$  (นั่นคือน้ำหนักประสาทของนิวรอนตัวที่  $i$ ) คือ

$${}_i\mathbf{w}^{new} = {}_i\mathbf{w}^{old} + e_i\mathbf{p} \quad (9.17)$$

และสำหรับไบอัสคือ

$$b_i^{new} = b_i^{old} + e_i \quad (9.18)$$

กฎการเรียนรู้แบบเพอร์เซ็ปตรอนสำหรับเครือข่ายหลายนิวรอนสามารถเขียนรวมในรูปของเมตริกซ์น้ำหนักประสาทได้คือ

$$\mathbf{W}^{new} = \mathbf{W}^{old} + \mathbf{e}\mathbf{p} \quad (9.19)$$

และสำหรับไบอัสคือ

$$\mathbf{b}^{new} = \mathbf{b}^{old} + \mathbf{e} \quad (9.20)$$

ตัวอย่างต่อไปนี้แสดงการทำงานและการเรียนรู้ของเครือข่ายเพอร์เซ็ปตรอน โดยเลือกใช้ตัวอย่างการเรียนรู้ของเพอร์เซ็ปตรอนเพื่อหาฟังก์ชันแทนตัวปฏิบัติการ OR ฟังก์ชันดังกล่าวถือว่าเป็นฟังก์ชันแบบไม่เป็นเชิงเส้น และไม่มีผลเฉลยรูปแบบปิดใดๆ ที่สามารถใช้แทนฟังก์ชันดังกล่าวได้ ตัวอย่างนี้แสดงให้เห็นถึงความสามารถของเครือข่ายประสาทเทียม ในอีกมุมมองหนึ่งที่ได้รับคามสนใจเป็นอย่างมาก ผู้อ่านเองควรทำความเข้าใจตัวอย่างดังกล่าวให้ถ่องแท้ เพื่อให้คุ้นเคยกับลักษณะการทำงานของเครือข่ายประสาทเทียมต่อไป เนื่องจากการทำงานของเครือข่ายประสาทเทียม จะมีความแตกต่างไปจากวิธีการคำนวณแบบดั้งเดิมค่อนข้างมาก

## ■ ตัวอย่างที่ 9.1 การเรียนรู้ของเครือข่ายเพอร์เซ็ปตรอน


พิจารณาปัญหาการฝึกสอนเพื่อแยกแยะของตัวปฏิบัติการ OR โดยมีเวกเตอร์อินพุตและเวกเตอร์เป้าหมายดังนี้ (ดูรูปที่ 9.6)

$$\left\{ \begin{aligned} \mathbf{p}_1 &= \begin{bmatrix} 0 \\ 0 \end{bmatrix}, \mathbf{t}_1 = [0] \\ \mathbf{p}_2 &= \begin{bmatrix} 0 \\ 1 \end{bmatrix}, \mathbf{t}_2 = [1] \\ \mathbf{p}_3 &= \begin{bmatrix} 1 \\ 0 \end{bmatrix}, \mathbf{t}_3 = [1] \\ \mathbf{p}_4 &= \begin{bmatrix} 1 \\ 1 \end{bmatrix}, \mathbf{t}_4 = [1] \end{aligned} \right\}$$

โดยที่  $\mathbf{p}_1 - \mathbf{p}_4$  คือเวกเตอร์อินพุตและ  $\mathbf{t}_1 - \mathbf{t}_4$  เป็นเวกเตอร์เป้าหมายของ  $\mathbf{p}_1 - \mathbf{p}_4$  ตามลำดับ ในรูปยังแสดงเส้นแบ่งพื้นที่จากเวกเตอร์น้ำหนักประสาท  ${}_1\mathbf{w}$  ซึ่งมีการกำหนดค่าเริ่มต้นคือ  ${}_1\mathbf{w} = [-1.2, -0.5]^T$  และไบอัส  $b$  มีค่าเริ่มต้นเท่ากับ 1.0 ค่าเอาต์พุตของเครือข่ายคือ

$$y = \text{hardlim}(w_{11}p_1 + w_{12}p_2 + b) \quad (9.21)$$

โดยที่  $\mathbf{p} = [p_1, p_2]^T$  ค่าของ  ${}_1\mathbf{w}$  และ  $b$  จะถูกปรับด้วยกฎการเรียนรู้ของเพอร์เซ็ปตรอน - II (ตามความสัมพันธ์ที่ (9.13) ข้างต้น) รายละเอียดเชิงตัวเลขมีแสดงในตารางที่ 9.1 ค่าเอาต์พุตของเครือข่ายจะถูกคำนวณจากเวกเตอร์อินพุตแต่ละตัว และจะนำไปเปรียบเทียบกับเวกเตอร์เป้าหมายของอินพุตนั้นๆ จากตารางดังกล่าว จะเห็นได้ว่าการเรียนรู้ของเครือข่ายหยุดลง เมื่อทำการคำนวณหาเอาต์พุตจากเวกเตอร์อินพุตทุกตัว แล้วค่าเอาต์พุตที่ได้เป็นไปตามเวกเตอร์เป้าหมายทุกๆ เวกเตอร์อินพุต (นั่นคือค่าความผิดพลาด  $e = 0$ ) รูปที่ 9.7 แสดงการปรับตัวของค่าน้ำหนักประสาท  ${}_1\mathbf{w}$  และไบอัส  $b$  ในระหว่างการเรียนรู้ของเครือข่าย



รูปที่ 9.6: เวกเตอร์อินพุตและเวกเตอร์เป้าหมายพร้อมเส้นแบ่งพื้นที่เริ่มต้น โดยที่  $P(1)$  และ  $P(2)$  แทนองค์ประกอบของอินพุตเวกเตอร์  $\mathbf{p} = [p_1, p_2]^T$

จากรูปที่ 9.7 จะเห็นได้ว่าการฝึกสอนเครือข่ายเพอร์เซ็ปตรอนจะขึ้นอยู่กับค่าเริ่มต้นของน้ำหนักประสาธและไบอัสด้วย ถ้าเส้นแบ่งพื้นที่ (หรือค่าน้ำหนักประสาธ) อยู่ใกล้กับคำตอบ การเรียนรู้ของเครือข่ายก็จะใช้เวลาเร็วขึ้นในการค้นหาเส้นแบ่งพื้นที่ที่ต้องการ ■

ตัวอย่างข้างต้นแสดงให้เห็นถึงการทำงานและกระบวนการเรียนรู้ของเครือข่ายเพอร์เซ็ปตรอน เราสามารถพิจารณาการฝึกสอนเครือข่ายประสาธเทียม ว่าเป็นการค้นหาค่าน้ำหนักประสาธและไบอัสที่เหมาะสมที่สุดของเครือข่ายได้

### 9.3 ข้อจำกัดของเครือข่ายเพอร์เซ็ปตรอน

การเรียนรู้ของเครือข่ายเพอร์เซ็ปตรอนได้รับการพิสูจน์ว่าเข้าสู่คำตอบได้ในจำนวนครั้งที่จำกัด (ไม่เป็นอนันต์) ตราบเท่าที่คำตอบนั้นมีอยู่จริง อย่างไรก็ตามเครือข่ายเพอร์เซ็ปตรอนไม่สามารถใช้ในการแก้ปัญหาบางอย่างได้ ในกรณีที่ผ่านมาเพอร์เซ็ปตรอนแบบนิวรอนเดียวสามารถตัดแยกพื้นที่อินพุตออกเป็น 2 พื้นที่ ซึ่งขอบเขตการแบ่งนิยามด้วยเส้นแบ่งพื้นที่

$$\mathbf{w} \cdot \mathbf{p} + b = 0 \quad (9.22)$$

จะเห็นได้ชัดว่าเส้นแบ่งพื้นที่ดังกล่าวเป็นเส้นตรง (ระนาบหลายมิติ) ดังนั้นเพอร์เซ็ปตรอนสามารถใช้กับเวกเตอร์อินพุตที่แบ่งได้ด้วยเส้นตรงเท่านั้น เราเรียกเส้นแบ่งพื้นที่ดังกล่าวว่าเป็นเส้นแบ่งพื้นที่ได้แบบเชิงเส้น (linearly separable) ตัวอย่างเช่นในปัญหาการกระทำ AND อย่างไรก็ตามปัญหาหลายๆ อย่างเป็นแบบแบ่งพื้นที่ได้แบบ

รอบที่	p	y	t	e	$w_{11}$	$w_{12}$	b
-	-	-	-	-	-1.2	-0.5	+1.0
1	p <sub>1</sub>	+1	0	-1	-1.2	-0.5	0.0
2	p <sub>2</sub>	0	+1	+1	-1.2	+0.5	+1.0
3	p <sub>3</sub>	0	+1	+1	-0.2	+0.5	+2.0
4	p <sub>4</sub>	+1	+1	0	-0.2	+0.5	+2.0
5	p <sub>1</sub>	+1	0	-1	-0.2	+0.5	+1.0
6	p <sub>2</sub>	+1	+1	0	-0.2	+0.5	+1.0
7	p <sub>3</sub>	+1	+1	0	-0.2	+0.5	+1.0
8	p <sub>4</sub>	+1	+1	0	-0.2	+0.5	+1.0
9	p <sub>1</sub>	+1	0	-1	-0.2	+0.5	0.0
10	p <sub>2</sub>	+1	+1	0	-0.2	+0.5	0.0
11	p <sub>3</sub>	0	+1	+1	+0.8	+0.5	+1.0
12	p <sub>4</sub>	+1	+1	0	+0.8	+0.5	+1.0
13	p <sub>1</sub>	+1	0	-1	+0.8	+0.5	0.0
14	p <sub>2</sub>	+1	+1	0	+0.8	+0.5	0.0
15	p <sub>3</sub>	+1	1	0	+0.8	+0.5	0.0
16	p <sub>4</sub>	+1	+1	0	+0.8	+0.5	0.0
17	p <sub>1</sub>	+1	0	-1	+0.8	+0.5	-1.0
18	p <sub>2</sub>	0	+1	+1	+0.8	+1.5	0.0
19	p <sub>3</sub>	+1	+1	0	+0.8	+1.5	0.0
20	p <sub>4</sub>	+1	+1	0	+0.8	+1.5	0.0
21	p <sub>1</sub>	+1	0	-1	+0.8	+1.5	-1.0
22	p <sub>2</sub>	+1	+1	0	+0.8	+1.5	-1.0
23	p <sub>3</sub>	0	+1	+1	+1.8	+1.5	0.0
24	p <sub>4</sub>	+1	+1	0	+1.8	+1.5	0.0
25	p <sub>1</sub>	+1	0	-1	+1.8	+1.5	-1.0
26	p <sub>2</sub>	+1	+1	0	+1.8	+1.5	-1.0
27	p <sub>3</sub>	+1	+1	0	+1.8	+1.5	-1.0
28	p <sub>4</sub>	+1	+1	0	+1.8	+1.5	-1.0
29	p <sub>1</sub>	0	0	0	+1.8	+1.5	-1.0


ตารางที่ 9.1: การปรับค่าน้ำหนักประสาทและไบอัสขณะเรียนรู้ของเครือข่ายเพอร์เซ็ปตรอน

ไม่เป็นเชิงเส้น (linearly inseparable) ยกตัวอย่างเช่นปัญหาอมตะ XOR หรือตัวอย่างในรูปที่ 9.8 อย่างไรก็ตาม ได้มีการนำเสนอเครือข่ายเพอร์เซ็ปตรอนแบบหลายชั้นสำหรับปัญหาแบบแบ่งพื้นที่ได้แบบไม่เป็นเชิงเส้น ซึ่งจะได้กล่าวถึงในรายละเอียดภายหลัง


## 9.4 การปรับแต่งกฎการเรียนรู้แบบเพอร์เซ็ปตรอน

กฎการเรียนรู้แบบเพอร์เซ็ปตรอนได้รับการปรับปรุงหลากหลายวิธี Mays [Widrow and Lehr, 1990] ได้เสนอวิธีการปรับปรุงกฎการเรียนรู้ดั้งเดิมของเพอร์เซ็ปตรอน 2 วิธี ทั้งสองวิธีเพิ่มการพิจารณาใช้พื้นที่เฉพาะ (dead zone) ในการเลือกการปรับค่าน้ำหนักประสาท พื้นที่เฉพาะดังกล่าวมีรัศมี  $\gamma$  ถ้าเน็ตเอาต์พุต  $n$  มีขนาดน้อยกว่า  $\gamma$





รูปที่ 9.7: การปรับตัวของเวกเตอร์น้ำหนักประสาทและไบอัสระหว่างการเรียนรู้ เส้นแบ่งพื้นที่ที่มีการเปลี่ยนแปลงตามค่าของ  $w_{11}$   $w_{12}$  และ  $b$  ที่เปลี่ยนแปลงตามกฎการเรียนรู้ของเพอร์เซ็ปตรอนในแต่ละรอบการคำนวณ



รูปที่ 9.8: ตัวอย่างปัญหาแบบแบ่งพื้นที่ได้แบบไม่เป็นเชิงเส้น

แสดงว่าเน็ตเอด์ฟุตอยู่ในพื้นที่เฉพาะนี้ (นั่นคือถ้า  $|n| < \gamma$ ) อัลกอริทึมในการปรับค่าน้ำหนักประสาทสามารถสรุปได้ดังนี้

▷ อัลกอริทึมการปรับส่วนเพิ่ม (increment adaptation algorithm)

$$\mathbf{w}^{new} = \begin{cases} \mathbf{w}^{old} + \alpha e \frac{\mathbf{p}}{\|\mathbf{p}\|^2} & \text{ถ้า } |n| \geq \gamma \\ \mathbf{w}^{old} + \alpha t \frac{\mathbf{p}}{\|\mathbf{p}\|^2} & \text{ถ้า } |n| < \gamma \end{cases} \quad (9.23)$$

โดยที่  $\alpha$  คือค่าคงที่การเรียนรู้ ถ้าพื้นที่เฉพาะนี้เป็นศูนย์ กฎการเรียนรู้ในสมการ (9.23) จะเป็นกฎการเรียนรู้แบบเพอร์เซ็ปตรอนทั่วไป เหมือนในสมการ (9.19) Mays ได้พิสูจน์กฎการเรียนรู้ข้างต้นแล้วว่าในกรณีแบ่งแยกได้เชิงเส้น (linearly separable) อัลกอริทึมดังกล่าวจะลู่เข้าสู่คำตอบเสมอ และสามารถที่จะแยกแยะรูปแบบได้ในจำนวนการเรียนรู้ที่จำกัด ในกรณีแบ่งแยกได้แบบไม่เป็นเชิงเส้น (nonlinearly separable) อัลกอริทึมนี้ยังมีประสิทธิภาพดีกว่ากฎการเรียนรู้ดั้งเดิมแบบเพอร์เซ็ปตรอนอันเนื่องมาจากพื้นที่เฉพาะ ถ้าพื้นที่เฉพาะมีขนาดใหญ่เพียงพอ การปรับเวกเตอร์น้ำหนักประสาทจะมีทิศทางที่ไม่เป็นเวกเตอร์ศูนย์ถ้ามีคำตอบที่ดีพออยู่จริง พื้นที่เฉพาะที่ใหญ่เพียงพอนี้ยังมีผลให้ค่าความผิดพลาดเฉลี่ยที่มีค่าต่ำ

สำหรับกฎการเรียนรู้แบบเพอร์เซ็ปตรอนดั้งเดิม อินพุตที่มีรูปแบบที่ไม่สามารถแยกได้แบบเชิงเส้นจะนำไปสู่จำนวนขั้นตอนการเรียนรู้ที่ไม่สิ้นสุด และโดยปกติแล้วจะให้ค่าความผิดพลาดเฉลี่ยที่มีค่าสูง Mays ยังได้พิสูจน์อีกว่าการใช้พื้นที่เฉพาะทำให้ลดความไวของค่าความผิดพลาดในน้ำหนักประสาทได้อีกด้วย

▷ อัลกอริทึมปรับปรุงการผ่อนคลาย (modified relaxation)

$$\mathbf{w}^{new} = \begin{cases} \mathbf{w}^{old} & \text{ถ้า } |n| \geq \gamma \text{ และ } e = 0 \\ \mathbf{w}^{old} + \alpha \hat{e} \frac{\mathbf{p}}{\|\mathbf{p}\|^2} & \text{อื่นๆ} \end{cases} \quad (9.24)$$

โดยที่  $\hat{e} = y - n$  ในกรณีที่พื้นที่เฉพาะมีขนาดเป็นอนันต์ ( $\gamma \rightarrow \infty$ ) อัลกอริทึมข้างต้นจะกลายเป็นกฎการเรียนรู้แบบเพอร์เซ็ปตรอนดั้งเดิม ถ้าพื้นที่เฉพาะเป็น  $0 < \gamma < 1$  และค่าคงที่การเรียนรู้  $0 < \alpha \leq 2$  อัลกอริทึมปรับปรุงการผ่อนคลายนี้จะลู่เข้าเสมอ และสามารถแยกแยะรูปแบบของอินพุต ที่เป็นแบบแยกแยะได้เชิงเส้นในจำนวนขั้นตอนการเรียนรู้ที่จำกัด แต่ถ้าอินพุตเป็นแบบแยกแยะได้แบบไม่เป็นเชิงเส้น อัลกอริทึมนี้จะทำงานเหมือนกับอัลกอริทึมการปรับส่วนเพิ่ม

## 9.5 สรุป

เนื้อหาในบทนี้ได้นำเสนอกฎการเรียนรู้แรก ที่เราได้ศึกษาสำหรับเครือข่ายประสาทเทียม อันได้แก่กฎการเรียนรู้แบบเพอร์เซ็ปตรอน ซึ่งเป็นการเรียนรู้แบบมีผู้ฝึกสอน กระบวนการฝึกสอนเครือข่ายเพอร์เซ็ปตรอนเริ่มจากการป้อนคู่ตัวอย่างอินพุต/เอาต์พุต (หรือเป้าหมาย) ให้กับเครือข่าย เครือข่ายจะทำการปรับค่าพารามิเตอร์ตามกฎการเรียนรู้ เพื่อให้เอาต์พุตของเครือข่ายเคลื่อนที่เข้าสู่เป้าหมายที่กำหนดไว้ในคู่ตัวอย่างอินพุต/เอาต์พุต

กฎการเรียนรู้แบบเพอร์เซ็ปตรอนเป็นกฎที่ไม่ซับซ้อน แต่ทรงประสิทธิภาพ กฎดังกล่าวจะลู่เข้าสู่คำตอบเสมอ (ถ้าคำตอบมีจริง) อย่างไรก็ตาม เครือข่ายเพอร์เซ็ปตรอนก็มีข้อจำกัด ที่ซึ่งไม่สามารถแก้ปัญหาที่แบ่งแยกได้แบบไม่เป็นเชิงเส้นได้ ข้อจำกัดดังกล่าวถูกแก้ไขด้วยเครือข่ายที่มีประสิทธิภาพมากกว่าเพอร์เซ็ปตรอน อันได้แก่เครือข่ายไปข้างหน้าแบบหลายชั้น รวมไปถึงกฎการเรียนรู้ที่ทรงประสิทธิภาพกว่ากฎการเรียนรู้แบบเพอร์เซ็ปตรอน ดังจะได้กล่าวถึงในหัวข้อต่อไป



## โจทย์คำถาม

9.1. ออกแบบเครือข่ายเพอร์เซ็ปตรอนในการคัดแยกอินพุตเวกเตอร์ที่มี 4 กลุ่มดังนี้


- กลุ่มที่ 1  $\left\{ p_1 = \begin{bmatrix} -0.5 \\ 2 \end{bmatrix}, p_2 = \begin{bmatrix} 1 \\ 2 \end{bmatrix} \right\}$
- กลุ่มที่ 2  $\left\{ p_3 = \begin{bmatrix} 1.5 \\ -0.5 \end{bmatrix}, p_4 = \begin{bmatrix} 2 \\ 1 \end{bmatrix} \right\}$
- กลุ่มที่ 3  $\left\{ p_5 = \begin{bmatrix} -2 \\ -1 \end{bmatrix}, p_6 = \begin{bmatrix} -1 \\ 1 \end{bmatrix} \right\}$
- กลุ่มที่ 4  $\left\{ p_7 = \begin{bmatrix} -1 \\ -1 \end{bmatrix}, p_8 = \begin{bmatrix} 1 \\ -1 \end{bmatrix} \right\}$

เครือข่ายเพอร์เซ็ปตรอนต้องออกแบบให้มีอย่างน้อย 2 นิวรอน (สำหรับ 4 กลุ่ม) โดยใช้โครงสร้างของเครือข่ายในรูปที่ 9.9 อินพุตเวกเตอร์ซึ่งแบ่งเป็น 4 กลุ่มพร้อมตัวอย่างเส้นแบ่งพื้นที่ 2 เส้นแสดงในรูปที่ 9.10 เวกเตอร์เป้าหมายสามารถกำหนดได้ดังนี้

- กลุ่มที่ 1  $\left\{ t_1 = \begin{bmatrix} 0 \\ 0 \end{bmatrix}, t_2 = \begin{bmatrix} 0 \\ 0 \end{bmatrix} \right\}$
- กลุ่มที่ 2  $\left\{ t_3 = \begin{bmatrix} 0 \\ 1 \end{bmatrix}, t_4 = \begin{bmatrix} 0 \\ 1 \end{bmatrix} \right\}$
- กลุ่มที่ 3  $\left\{ t_5 = \begin{bmatrix} 1 \\ 0 \end{bmatrix}, t_6 = \begin{bmatrix} 1 \\ 0 \end{bmatrix} \right\}$
- กลุ่มที่ 4  $\left\{ t_7 = \begin{bmatrix} 1 \\ 1 \end{bmatrix}, t_8 = \begin{bmatrix} 1 \\ 1 \end{bmatrix} \right\}$


จากรายละเอียดข้างต้น ให้ตอบคำถามต่อไปนี้

- ให้ออกแบบคำนวณหาค่าเมตริกซ์น้ำหนักประสาทและไบอัส (มีได้หลายคำตอบ) แสดงรายละเอียดการออกแบบและคำนวณ วิเคราะห์และสรุปผลที่ได้
- ปรับปรุงการเรียนรู้ของเพอร์เซ็ปตรอนโดยใช้วิธีของ Mays ทดลองเลือกค่าพารามิเตอร์ต่างๆ และวิเคราะห์ผลลัพธ์ที่ได้ โดยเปรียบเทียบกับการเรียนรู้เพอร์เซ็ปตรอนแบบดั้งเดิม




รูปที่ 9.9: เพอร์เซ็ปตรอนแบบ 2 นิวรอน

9.2. เพอร์เซ็ปตรอนสามารถใช้เป็นตัวกระทำทางลอจิกได้ จงออกแบบเครือข่ายเพอร์เซ็ปตรอนที่ทำหน้าที่ฟังก์ชันลอจิกแบบไบนารี AND OR NOT และ COMPLEMENT อภิปรายพารามิเตอร์ในการออกแบบและผลลัพธ์ที่ได้




รูปที่ 9.10: อินพุตเวกเตอร์และเส้นแบ่งพื้นที่



รูปที่ 9.11: ข้อมูล 2 กลุ่มในระนาบ 3 มิติ

- 9.3. รูปที่ 9.11 แสดงข้อมูล 2 กลุ่มในระนาบ 3 มิติ จงออกแบบเครือข่ายเพอร์เซ็ปตรอนในการแบ่งกลุ่มข้อมูลในรูป พร้อมแสดงรายละเอียดการฝึกสอนและอภิปรายผลลัพธ์ที่ได้
- 9.4. จงทดลองออกแบบเครือข่ายเพอร์เซ็ปตรอนสำหรับฟังก์ชันลอจิก XOR แบบ 2 มิติ อภิปรายผลลัพธ์ที่ได้ (หมายเหตุ เครือข่ายเพอร์เซ็ปตรอนไม่สามารถใช้ป็นฟังก์ชันลอจิก XOR ได้)
- 9.5. เพอร์เซ็ปตรอนสามารถใช้เป็นตัวตัดแยกเชิงเส้น (linear classifier) ได้ จงพิจารณาออกแบบเครือข่ายเพอร์เซ็ปตรอนสำหรับตัดแยกตัวเลขในรูปที่ 9.12 โดยจำนวนของนิวรอนในเครือข่ายจะต้องมีขนาดเท่ากับจำนวนหลักของตัวเลข แต่ละหลักแทนด้วยเมตริกซ์ขนาด  $5 \times 4$  (ทำการแปลงให้อยู่ในรูปเวกเตอร์ก่อนที่จะป้อนให้กับเครือข่าย) เอาต์พุตของแต่ละนิวรอนจะสัมพันธ์กับหลักของตัวเลข เช่นเอาต์พุตของนิวรอนตัวที่ 1 ควรจะตอบสนองกับอินพุตที่เป็นเลข 1 เมื่อทำการฝึกสอนและทดสอบเครือข่ายแล้วให้ทำการใส่สัญญาณรบกวนให้กับอินพุต แล้วทำการทดสอบกับเครือข่ายอีกครั้ง สังเกตประสิทธิภาพของเครือข่าย พร้อมทั้งอภิปรายผลลัพธ์ที่ได้



รูปที่ 9.12: เวกเตอร์ตัวเลข 10 หลัก

*[Handwritten signature]*



- W.S. McCulloch and W. Pitts. A logical calculus of ideas immanent in nervous activity. In *Bulletin of Mathematical Biophysics*, volume 5, pages 115--133, 1943.
- F. Rosenblatt. The perceptron: A probabilistic model for information storage and organization in the brain. In *Psychological Review*, volume 65, pages 386--408, 1958.
- F. Rosenblatt. On the convergence of reinforcement procedures in simple perceptrons. Report, Cornell Aeronautical Lab, February 1960.
- F. Rosenblatt. *Principles of Neurodynamics: Perceptrons and the Theory of Brain Mechanisms*. Washington: Spartan Books, 1962.
- B. Widrow and M.A. Lehr. 30 years of neural networks: Perceptron, madaline and backpropagation. In *Proceedings of the IEEE*, volume 78, pages 1415--1442, 1990.



Handwritten signature and a circled number 2.