


การหาค่าเหมาะที่สุดด้วยคอลนีมด Ant Colony Optimization

เขาวนปัญหาเชิงการเคลื่อนที่เป็นกลุ่มได้แรงบันดาลใจมาจากพฤติกรรมทางสังคม ของแมลงหรือสัตว์ที่อยู่รวมกันเป็นฝูงอื่นๆ โดยเฉพาะมด ซึ่งถือเป็นแมลงสังคมที่ได้รับความสนใจในพฤติกรรมและนำไปพัฒนาเป็นเทคนิคต่างๆ ในงานการหาค่าเหมาะที่สุดอย่างมากมาย โดยรู้จักในชื่อของการหาค่าเหมาะที่สุดด้วยคอลนีมด (ant colony optimization หรือ ACO) เทคนิคดังกล่าวได้แรงบันดาลใจมาจากพฤติกรรมการออกหาอาหารของมดบางชนิด มดเหล่านี้จะทำการปล่อยฟีโรโมน (pheromone) ไว้ตามทางที่เดินผ่าน โดยมีจุดประสงค์เพื่อทำเครื่องหมายเส้นทางที่ตนเองพอใจ (เส้นทางที่สั้นกว่านั่นเอง) มดตัวอื่นในคอลนีจะเดินตามเส้นทางที่มีฟีโรโมนดังกล่าวพร้อมทั้งปล่อยฟีโรโมนให้สะสมระหว่างเส้นทางมากยิ่งขึ้น ACO ใช้หลักการคล้ายคลึงกันกับมดเป็นกลไกในการแก้ปัญหาการหาค่าเหมาะที่สุด

นับจากต้นศตวรรษที่ 19 ที่ซึ่งอัลกอริทึมแรกๆ ของ ACO ได้ถูกนำเสนอ ACO ก็ได้รับความสนใจจากนักวิจัยมากมาย รวมไปถึงความสำเร็จในการนำไปประยุกต์ใช้งานได้อย่างหลากหลาย นอกเหนือไปจากนั้นแล้ว ต่อมาตัวทฤษฎีของ ACO เองก็ได้รับการพิสูจน์อย่างกว้างขวาง ซึ่งเป็นประโยชน์ต่อการพัฒนาของนักวิจัยและผู้นำเอาไปใช้งานจริงในการประยุกต์ใช้งานต่างๆ เพิ่มมากขึ้นอีก ACO บทความใน [Dorigo et al., 2006] ซึ่งเขียนโดย Marco Dorigo หนึ่งในทีมงานผู้คิดค้น ACO เอง นำเสนอเรื่องราวของ ACO จากจุดเริ่มต้น จนกระทั่งถึงสถานะภาพปัจจุบันของการพัฒนา ACO เว็บไซต์ <http://www.aco-metaheuristic.org> ของทีมงานผู้คิดค้น ACO อีกเช่นกัน ถือเป็นจุดเริ่มต้นในการศึกษารายละเอียดของ ACO ได้เป็นอย่างดี ในหัวข้อต่อไปจะได้กล่าวถึงที่มา อัลกอริทึมและการประยุกต์ใช้งาน ACO ซึ่งผู้เขียนได้เรียบเรียงมาจากแหล่งข้อมูลหลายๆ แหล่ง โดยเฉพาะจากแหล่งที่กล่าวไว้ข้างต้น และได้ทำการเพิ่มเติมเนื้อหาที่จำเป็น เพื่อให้สามารถเข้าใจหลักการของ ACO ได้ดียิ่งขึ้น

7.1 แรงบันดาลใจจากธรรมชาติ

ถึงแม้ว่ามด ในทางกายภาพแล้วถือว่ามีประสิทธิภาพในการมองเห็นที่ต่ำ แต่มดสามารถเดินทางและสำรวจในสภาวะแวดล้อมที่ซับซ้อนได้ และยังสามารถหาแหล่งอาหาร ที่ซึ่งห่างไกลจากรังของมันได้ พร้อมกับสามารถเดินทางกลับรังได้อย่างถูกต้อง มดใช้หลักการปล่อยสารฟีโรโมนในขณะทำการสำรวจสภาวะแวดล้อมของมัน กระบวนการดังกล่าวนี้เรียกว่า “stigmergy” แนวคิดของ stigmergy ถูกนำเสนอโดยนักสัตววิทยาทางแมลงชาวฝรั่งเศสชื่อ



รูปที่ 7.1: การทดลองสะพานคู่ จุดในสะพานแทนตัวมด (ก) สะพานทั้งสองมีความยาวเท่ากัน (ข) สะพานทั้งสองยาวไม่เท่ากัน


Pierre-Paul Grasse ในช่วงทศวรรษที่ 50 แนวคิดดังกล่าวนิยาม stigmergy ว่าเป็นการสื่อสารแบบทางอ้อม (indirect) ที่เกิดขึ้นระหว่างแมลงแต่ละตัวในฝูงแมลง การสื่อสารทางอ้อมดังกล่าวนี้ เกิดจากการปรับเปลี่ยนสถานะแวดล้อมของตัวแมลง (เช่นปล่อยฟีโรโมน) เพื่อสื่อไปถึงแมลงตัวอื่นๆ รวมไปถึงฝูงของแมลง รวมไปถึงการทิ้งร่องรอยไว้สำหรับเดินทางกลับรังด้วย การสื่อสารที่เกิดขึ้นนี้มีลักษณะเป็นแบบเฉพาะถิ่น นั้นหมายถึงการจะเข้าถึงข้อมูลที่แมลงหนึ่งๆ ทิ้งเอาไว้ ตัวแมลงนั้นๆ จะต้องอยู่ในพื้นที่ที่มีการปล่อยข้อมูลนั้นไว้ด้วย

ตัวอย่างของ stigmergy สามารถสังเกตได้จากคอลโลนีของมดดังกล่าวมาแล้วข้างต้น มดบางชนิดจะทำการเดินไปยังแหล่งอาหารและกลับมารัง โดยทำการปล่อย “ฟีโรโมน” ไว้ตามพื้นที่มันเดินผ่าน มดตัวอื่นที่เดินมาเจอฟีโรโมนจะมีแนวโน้มที่จะเดินตามในทิศที่มีฟีโรโมนที่หนาแน่นกว่า ด้วยกลไกดังกล่าว มดสามารถขนย้ายอาหารไปยังรังได้ในเส้นทางที่มีประสิทธิภาพมากที่สุด

งานใน [Deneubourg et al., 1990] นำเสนอรายละเอียดการปล่อยฟีโรโมนและพฤติกรรมการเดินทางฟีโรโมนของมด ในการทดลองที่เรียกว่า “สะพานคู่” (double bridge experiment) รังของมดอาร์เจนตินาถูกเชื่อมต่อกับแหล่งอาหารโดยสะพาน 2 สะพานที่มีความยาวเท่ากัน พิจารณาสถานะในรูปที่ 7.1(ก) ในการทดลองดังกล่าว มดจะเริ่มทำการสำรวจรอบๆ รังจนกระทั่งไปเจอแหล่งอาหาร ระหว่างทางที่มดได้เดินสำรวจ มดจะทำการปล่อยฟีโรโมน ในตอนเริ่มต้น มดแต่ละตัวจะเลือกสะพานทั้งสองอย่างสุ่ม ซึ่งเมื่อเวลาผ่านไประยะหนึ่ง สะพานใดสะพานหนึ่งจะมีความเข้มข้นของฟีโรโมนมากกว่าอีกสะพานหนึ่ง ซึ่งมดจะเลือกเดินผ่านสะพานนั้นมากกว่า และเมื่อมีมดเดินผ่านสะพานนั้นๆ มากขึ้นแล้ว ระดับความเข้มข้นของฟีโรโมนจากมดก็จะเพิ่มมากขึ้น ทำให้ท้ายสุดแล้วจะมีการลู่ของมดทั้งรังสู่การเดินทางผ่านสะพานนั้นๆ เพียงสะพานเดียว Deneubourg และผู้ร่วมวิจัยทำการทดลองซ้ำเป็นจำนวนหลายๆ ครั้ง และสังเกตพบว่าแต่ละสะพานจะมีโอกาสถูกเลือกใช้ประมาณ 50% พฤติกรรมระดับกลุ่มของมดนี้สามารถถูกใช้ในการหาเส้นทางที่สั้นที่สุดระหว่างแหล่งอาหารกับรังมดได้ พฤติกรรมดังกล่าวเรียกว่าเป็นการเร่งปฏิกิริยาเอง (autocatalysis) Goss และคณะ [Goss et al., 1989] ทำการปรับการทดลองสะพานคู่ใหม่ โดยปรับให้สะพานหนึ่งมีความยาวมากกว่าอีกสะพานหนึ่งอย่างเห็นได้ชัด ดูสะพานในรูป 7.1(ข) ประกอบ ในกรณีนี้แนวโน้มในการสุ่มเลือกสะพานจะลดลง มดจะทำการเลือกสะพานที่สั้นกว่าในการเดินทางกลับรัง สะพานที่สั้นกว่าจะมีการสะสมของฟีโรโมนมากกว่า และเป็นส่วนที่ทำให้ค่าความน่าจะเป็นในการเลือกสะพานที่สั้นกว่าสูงกว่าสะพานที่ยาวกว่า Goss และคณะเองยังได้ทำการพัฒนาแบบจำลองพฤติกรรมที่สังเกตได้ดังนี้

$$p_1 = \frac{(m_1 + k)^h}{(m_1 + k)^h + (m_2 + k)^h} \quad (7.1)$$

โดยที่ m_1 คือจำนวนมดที่ได้เดินผ่านสะพานแรกและ m_2 คือจำนวนมดที่ได้เดินผ่านสะพานที่สอง p_1 คือค่าความน่าจะเป็นที่มดจะเลือกสะพานแรก k และ h เป็นพารามิเตอร์ของการทดลอง จากความสัมพันธ์ดังกล่าวเราจะได้ว่า $p_2 = 1 - p_1$ จากการจำลองสถานะการณ์แบบมอนติคาร์โล ค่าพารามิเตอร์ที่เหมาะสมกับการทดลองคือ $k \approx 20$ และ $h \approx 2$



รูปที่ 7.2: TSP: ถ้าเซลล์แมนเริ่มต้นที่เมือง A วัตถุประสงค์คือการหาเส้นทางที่สั้นที่สุดที่เดินทางไปยังทุกเมือง B,C,D แล้วกลับมาที่เมือง A

7.2 อัลกอริทึมของ ACO

Dorigo ได้นำเสนออัลกอริทึมของ ACO ไว้ในวิทยานิพนธ์ของเขาเอง [Dorigo, 1992] อัลกอริทึมดังกล่าวถือเป็นงานยุคแรกๆ ของ ACO ซึ่งต่อมาได้มีผู้พัฒนาอัลกอริทึมแบบต่างๆ ของ ACO ไว้มากมาย (ดูใน [Dorigo et al., 2006]) ในการนำเสนออัลกอริทึมของ ACO นั้น Dorigo เลือกใช้ปัญหาการเดินทางของเซลล์แมน (Traveling Salesman Problem หรือ TSP) ในการอธิบายการทำงานของอัลกอริทึม TSP เป็นปัญหาการเลือกเส้นทางเดินทางที่เป็นที่นิยมมาก ปัญหาดังกล่าวก็คือการเดินทางไปเมืองต่างๆ ตามที่กำหนดเมืองละหนึ่งครั้งให้ครบทุกเมือง วัตถุประสงค์ของ TSP ก็คือการเลือกเส้นทางเดินทางที่สั้นที่สุด ได้มีผู้นำเสนออัลกอริทึมการแก้ TSP ไว้มากมาย โดยเน้นไปที่ประสิทธิภาพในการค้นหาให้ได้คำตอบที่เหมาะสมที่สุด ในเวลาน้อยที่สุด ตัวอย่างการนำไปใช้งานจริงของ TSP เช่นการวางแผนการเคลื่อนที่ของแขนกลในการเจาะรูบนแผ่นวงจร PCB

ใน TSP เซตของเมืองจะถูกกำหนดไว้ รวมไปถึงระยะทางระหว่างเมืองแต่ละเมือง เป้าหมายในการแก้ปัญหาคือการหาเส้นทางที่สั้นที่สุดที่จะเดินทางไปแต่ละเมืองเพียงครั้งเดียวได้ครบทุกเมือง จริงๆ แล้ว TSP ก็คือการหาเส้นทางแบบ Hamiltonian ที่สั้นที่สุดของการเชื่อมต่อเต็มรูปแบบระหว่างโนดทุกโนด (ดูรูปที่ 7.2) สำหรับ TSP ใน ACO แล้ว มดประดิษฐ์ (artificial ant) จำนวนมากจะถูกส่งออกเดินทางไปตามเส้นทางระหว่างโนดของปัญหา โหนดดังกล่าวก็คือเมืองต่างๆ นั่นเอง ระหว่างโนดจะเป็นเส้นทางที่รู้ระยะ ตัวแปรฟีโรโมนจะถูกกำหนดตามเส้นทางเดินทางทั้งหมด ซึ่งตัวแปรดังกล่าวสามารถถูกอ่านค่าและปรับเปลี่ยนค่าได้ด้วยมดประดิษฐ์ที่เดินผ่าน กำหนดให้จำนวนเมืองทั้งหมดใน TSP เท่ากับ N รายละเอียดของอัลกอริทึม ACO สำหรับ TSP มีดังต่อไปนี้

▷ อัลกอริทึม ACO

1. ทำการสุ่มปริมาณฟีโรโมนเริ่มต้น $\tau_{ij}(0)$ ของแต่ละเส้นทาง (i, j) ระหว่างเมือง i และเมือง j ด้วยค่าสุ่มบวกจำนวนน้อยๆ นั่นคือ $\tau_{ij}(0) \sim U(0, max)$ เป็นค่าสุ่มที่มีการแจกแจงแบบสม่ำเสมอระหว่าง 0 ถึง max (กำหนดค่า max เอง)
2. ทำการเริ่มปล่อยมดประดิษฐ์ตัวที่ k โดยที่ $k \in 1, \dots, M$ ณ เมืองหรือจุดเริ่มต้น
3. กำหนดให้ T^+ เป็นเส้นทางเดินที่สั้นที่สุดและ L^+ เป็นระยะทางของเส้นทางที่สั้นที่สุดนั้น
4. กำหนดช่วงเวลาใน $t = 1$ ถึง t_{max} ทำซ้ำขั้นตอนต่อไปนี

(a) สำหรับมดประดิษฐ์แต่ละตัว ทำการสร้างเส้นทาง $T_k(t)$ ของมดตัวที่ k โดยทำการเลือกเมืองถัดไป

ทั้งหมด $N - 1$ ครั้ง ด้วยค่าความน่าจะเป็น

$$\Phi_{ij}^k(t) = \begin{cases} \frac{\tau_{ij}(t)^\alpha}{\tau_c(t)} & \text{ถ้า } j \in C_i^k \\ 0 & \text{ถ้า } j \notin C_i^k \end{cases} \quad (7.2)$$

โดยที่ตัวชี้ k แทนมดประดิษฐ์ตัวที่ k ส่วน $\tau_{ij}(t)$ เป็นปริมาณของฟีโรโมนในเส้นทาง (i, j) ระหว่างเมือง i และเมือง j ค่า α เป็นค่าคงที่ C_i^k เป็นเซตของเมืองที่มดตัวที่ k ยังไม่ได้เดินทางไป โดยนับจากเมือง i ส่วน $\tau_c(t)$ เป็นผลรวมของฟีโรโมนในเส้นทางทั้งหมดของ C_i^k นั่นคือ $\tau_c(t) = \sum_{c \in C_i^k} \tau_{ic}(t)^\alpha$

- (b) คำนวณระยะทางการเดินทาง $L_k(t)$ ของมดประดิษฐ์ตัวที่ k
- (c) ถ้าพบเส้นทางที่ดีกว่า ให้ทำการบันทึกค่าแทน T^+ และ L^+
- (d) ทำการปรับค่าฟีโรโมนของแต่ละเส้นทางดังนี้

$$\tau_{ij}(t+1) = (1 - \rho)\tau_{ij}(t) + \Delta\tau_{ij}(t) \quad (7.3)$$

โดยที่ $\Delta\tau_{ij}(t) = \sum_{k=1}^M \Delta\tau_{ij}^k(t)$ เป็นค่าผลรวมของฟีโรโมนที่ปล่อยโดยมดแต่ละตัว ซึ่งคำนวณได้จาก

$$\Delta\tau_{ij}^k(t) = \begin{cases} Q/L_k(t) & \text{ถ้า } (i, j) \in T_k(t) \\ 0 & \text{ถ้า } (i, j) \notin T_k(t) \end{cases} \quad (7.4)$$

Q เป็นพารามิเตอร์ของระบบ ค่าคงที่ $\rho \in [0, 1]$ เรียกว่าตัวประกอบการลืม (forgetting factor) ที่ซึ่งแทนการจางหายไปของฟีโรโมนเมื่อเวลาผ่านไป (ค่า ρ ที่มากกว่า จะมีผลให้ฟีโรโมนจางหายไปเร็วขึ้น)

ค่าความน่าจะเป็นในการเลือกเส้นทางสามารถปรับปรุงได้โดยการเพิ่มข้อมูลเฉพาะถิ่นของเมืองที่ต้องการไป j จากเมือง i ได้ดังนี้

$$\Phi_{ij}^k(t) = \frac{\tau_{ij}(t)^\alpha \eta_{ij}^\beta}{\sum_{c \in C_i^k} \tau_{ic}(t)^\alpha \eta_{ic}^\beta} \quad (7.5)$$

โดยที่ α และ β เป็นพารามิเตอร์ของระบบที่ควบคุมน้ำหนักของฟีโรโมนและข้อมูลเฉพาะถิ่น และ

$$\eta_{ij} = \frac{1}{d_{ij}} \quad (7.6)$$

โดยที่ d_{ij} เป็นระยะทางยูคลิด (Euclidean distance) ระหว่างเมือง i และเมือง j (พิจารณาในระนาบสองมิติ) สังเกตว่าค่าของ Φ_{ij}^k อาจจะแตกต่างกันสำหรับมดแต่ละตัว ณ เมืองเดียวกันได้ อันเนื่องมาจากมดแต่ละตัวอาจจะมาถึงเมืองนั้นๆ ด้วยเส้นทางที่แตกต่างกัน

อัลกอริทึมแบบจำลองพฤติกรรมของมดข้างต้นมีพารามิเตอร์ของระบบที่ต้องพิจารณาค่อนข้างมาก พารามิเตอร์ที่ถือว่าสำคัญที่สุดคือตัวประกอบการลืมสำหรับการจางหายไปของฟีโรโมน และจำนวนของมดประดิษฐ์ M ในระบบ ในลักษณะเดียวกันกับอัลกอริทึมประเภทอื่นๆ จำนวนมดที่มากเกินไปจะใช้เวลาในการคำนวณมากไปด้วย รวมไปถึงพฤติกรรมการลู่เข้าสู่คำตอบที่ไม่ใช่คำตอบที่เหมาะสมที่สุดอย่างรวดเร็วเกินไป ในทางตรงกันข้าม จำนวนมดประดิษฐ์ที่น้อยเกินไปทำให้การทำงานร่วมกันของมดไม่เพียงพอต่อการค้นหาคำตอบที่เหมาะสมที่สุด นอกเหนือไปจากพารามิเตอร์เหล่านี้แล้ว พารามิเตอร์ α และ β ยังเป็นสิ่งที่ต้องคำนึงถึง ถ้า $\beta = 0$ แสดงว่าระบบใช้ข้อมูลจากฟีโรโมนเพียงอย่างเดียว ซึ่งอาจจะนำไปสู่คำตอบที่ไม่ใช่คำตอบที่เหมาะสมที่สุดได้ ถ้า $\alpha = 0$ แสดงว่าระบบไม่ใช้ข้อมูลของฟีโรโมนเลย การค้นหาของมดจะกลายเป็นเพียงการค้นหาคำตอบแบบตะกวดตะกลาม

อัลกอริทึม ACO ได้รับความสนใจและมีการปรับแต่งอย่างหลากหลาย ตัวอย่างของอัลกอริทึมที่ถูกยอมรับในความสำเร็้อมีดังเช่น Ant System (AS) [Dorigo et al., 1996] Elitist AS [Dorigo, 1992] ANT-Q [Gambardella and Dorigo, 1995] Ant Colony System [Dorigo and Gambardella, 1997a][Dorigo and Gambardella, 1997b][Gambardella and Dorigo, 1996] $MAX - MIN$ AS [Stützle and Hoos, 2000] Rank-Based AS [Bullnheimer et al., 1999] ANTS [Maniezzo, 1999] BWAS [Cordón et al., 2000] Hyper-Cube AS [Blum et al., 2001][Blum and Dorigo, 2004]

7.3 คอลนีมดกับการจับกลุ่มข้อมูล Ant Colony & Data Clustering

ในหัวข้อที่ผ่านมาได้นำเอาพฤติกรรมของการออกหาอาหารของมด มาใช้ในการแก้ปัญหาที่เหมาะสมที่สุด ในหัวข้อนี้จะได้นำถึงรายละเอียดตัวอย่างการใช้พฤติกรรมจับกลุ่มและจัดเรียง (clustering & sorting) ของมด เพื่อใช้เป็นอัลกอริทึมการจับกลุ่มข้อมูลได้

มีมดอยู่หลายๆ ชนิดที่ทำการจับกลุ่มซากมดที่ตายแล้วไปยังส่วนที่เป็น “ป่าช้า” นัยว่าเพื่อเป็นการทำความสะอาดรังของมดเองด้วย การทดลองหลายๆ อย่างแสดงให้เห็นว่า มดทำการจับกลุ่มซากมด โดยเริ่มต้นอย่างไม่เป็นระเบียบ ให้อยู่เป็นกองในพื้นที่หนึ่งๆ ได้ในระยะเวลาอันสั้น (2-3 ชั่วโมง) พฤติกรรมดังกล่าวยังไม่เป็นที่เข้าใจชัดเจนนัก แต่ดูเหมือนว่าจะมีกลไกการป้อนกลับบางอย่าง ที่คำนวณความน่าจะเป็นสำหรับมดงานที่จะยกซากมดและนำไปทิ้งในที่ๆ ต้องการ พฤติกรรมดังกล่าวถูกนำมาสร้างเป็นแบบจำลองอย่างง่าย ๆ จากงานของ [Bonabeau et al., 1999] สำหรับใช้เป็นอัลกอริทึมจับกลุ่มข้อมูล

แนวคิดทั่วไปของพฤติกรรมในการจับกลุ่มของมดคือ ให้มดประดิษฐ์จำนวนหนึ่งเดินไปในปริภูมิค้นหา แล้วทำการหยิบข้อมูลหรือปล่อยข้อมูล โดยตัดสินใจจากค่าความน่าจะเป็น พร้อมกับมาตรวัดความคล้ายของข้อมูลที่ต้องการจับกลุ่ม พิจารณาระบบที่มีข้อมูลอยู่เพียงประเภทเดียว และข้อมูลดังกล่าวจะจัดกระจายไปทั่วปริภูมิค้นหา ค่าความน่าจะเป็นในการที่ข้อมูลจะถูกหยิบโดยมดประดิษฐ์คือ

$$p_p = \left(\frac{k_1}{k_1 + f} \right)^2 \quad (7.7)$$

โดยที่ f เป็นเศษส่วนของข้อมูลที่มีมดสามารถหยิบจับได้ในรอบย่านการทำงาน k_1 เป็นค่าคงที่ ถ้าไม่มีข้อมูลมากนักในย่านมดประดิษฐ์นั้นๆ อยู่ แสดงว่า $f \ll k_1$ ค่าของ $p_p \rightarrow 1$ นั่นคือข้อมูลนั้นมีโอกาสสูงที่จะถูกหยิบไว้โดยมดประดิษฐ์ ที่ซึ่งแสดงว่าข้อมูลดังกล่าวไม่ควรจะอยู่ตรงนั้น และควรจะถูกหยิบนำไปยังที่ๆ ถูกต้องโดยมดประดิษฐ์ในทางตรงกันข้าม ถ้ามดสังเกตเห็นข้อมูลที่มีมาก ($f \gg k_1$) ค่าของ $p_p \rightarrow 0$ โอกาสที่ข้อมูลนั้นจะถูกหยิบไว้โดยมดประดิษฐ์จะมีค่าน้อย ดังนั้นข้อมูลดังกล่าวจะถูกพิจารณาว่าอยู่ในที่ๆ ถูกต้องแล้ว

มดประดิษฐ์แต่ละตัวจะใช้ค่าความน่าจะเป็นในการปล่อยข้อมูลที่หยิบเอาไว้ดังนี้

$$p_d = \left(\frac{f}{k_2 + f} \right)^2 \quad (7.8)$$

โดยที่ k_2 เป็นค่าคงที่ ถ้ามดสังเกตเห็นจำนวนข้อมูลที่มีมากในย่านการทำงานของมัน ($f \gg k_2$) ค่า $p_d \rightarrow 1$ โอกาสที่มดจะปล่อยข้อมูลไว้ ณ ย่านนี้จะมีค่าสูง ถ้า $f \ll k_2$ แสดงว่า $p_d \rightarrow 0$ มดจะหยิบเอาข้อมูลนั้นเดินทางต่อไปในย่านอื่นๆ

เศษส่วนของข้อมูล f สามารถคำนวณได้จากการใช้หน่วยความจำระยะสั้น (short-term memory) ของมดแต่ละตัว กล่าวคือมดแต่ละตัวจะจดจำข้อมูลไว้ในช่วงเวลาล่าสุด T หน่วยเวลาเท่านั้น และ f ก็คือจำนวนของข้อมูลที่มีมดแต่ละตัวค้นพบในย่านที่ค้นหาอยู่ในช่วงเวลา T นั้นๆ หากด้วยจำนวนข้อมูลมากที่สุดที่ได้ค้นพบในช่วงเวลา T อื่นๆ ที่ผ่านมา

ในการออกแบบใช้กลไกข้างต้นในการจับกลุ่มข้อมูล วัตถุประสงค์ของการจับกลุ่มจะเป็นไปตามนี้

- **ระยะภายในกลุ่ม (intra-cluster)** จะต้องมีย่านที่น้อยที่สุด นั่นคือระยะทางระหว่างข้อมูลภายในกลุ่มเดียวกัน จะต้องมีย่านน้อยเพื่อให้ข้อมูลจับกลุ่มใกล้เคียงกัน
- **ระยะระหว่างกลุ่ม (inter-cluster)** จะต้องมีย่านมากที่สุด นั่นคือกลุ่มต่างๆ ของข้อมูลจะต้องแยกจากกัน อย่างชัดเจน

การใช้คอลอนีมดในการจับกลุ่มข้อมูลนั้น มีขั้นตอนที่คล้ายคลึงกับการทำงานของแผนผังคุณลักษณะการจัดการตนเอง (Self-Organizing Map หรือ SOM) ซึ่งผู้อ่านสามารถดูรายละเอียดในหัวข้อการเรียนรู้ของเครือข่ายประสาทเทียมได้ การจับกลุ่มดังกล่าวคือการจับกลุ่มข้อมูลที่มีมิติสูงกว่า ให้อยู่ในกริดสองมิติที่มีขนาดเล็กกว่า การจับกลุ่มในกริดสองมิติจะสามารถรักษาความสัมพันธ์ระหว่างข้อมูลที่มาจากปริภูมิที่มีมิติสูงกว่าได้ ในกรณีของคอลอนีมด มดประดิษฐ์จะเดินไปตามกริดสองมิติดังกล่าว พร้อมกับทำการสังเกตพื้นที่รอบข้างขนาด s^2 ที่ซึ่งเป็นพื้นที่จัตุรัส $\mathcal{N}_{s \times s}(r)$ รอบๆ ตำแหน่งปัจจุบัน r ขนาด $s \times s$ ของมดนั่นเอง สมมติว่า ณ เวลา t มดที่ตำแหน่ง r บนกริดค้นพบข้อมูลเวกเตอร์ \vec{z}_i ความหนาแน่นหรือเศษส่วน $f(\vec{z}_i)$ ของข้อมูลเวกเตอร์ภายในพื้นที่ทำการของมดสามารถคำนวณได้จาก

$$f(\vec{z}_i) = \begin{cases} \frac{1}{s^2} \sum_{\vec{z}_j \in \mathcal{N}_{s \times s}} \left[1 - \frac{d(\vec{z}_i, \vec{z}_j)}{\alpha} \right] & \text{ถ้า } f > 0 \\ 0 & \text{นอกจากนั้นแล้ว} \end{cases} \quad (7.9)$$

โดยที่ $d(\vec{z}_i, \vec{z}_j)$ เป็นมาตรวัดความแตกต่างระหว่างเวกเตอร์ \vec{z}_i และเวกเตอร์ \vec{z}_j (เช่นระยะทางยุคลิด) ค่าคงที่ α เป็นสัดส่วนสำหรับควบคุมความแตกต่าง ที่ซึ่งใช้กำหนดว่าเวกเตอร์ \vec{z}_i และเวกเตอร์ \vec{z}_j จะต้องแตกต่างกันมากน้อยเพียงใดสำหรับการจับกลุ่ม ค่า $f(\vec{z}_i)$ เป็นค่าวัดความแตกต่างของเวกเตอร์ \vec{z}_i กับข้อมูลเวกเตอร์อื่นๆ ในย่าน $\mathcal{N}_{s \times s}$


ค่าความน่าจะเป็นในการหยิบและปล่อยข้อมูลเวกเตอร์ \vec{z}_i สามารถคำนวณได้จาก

$$p_p(\vec{z}_i) = \left(\frac{k_1}{k_1 + f(\vec{z}_i)} \right)^2 \quad (7.10)$$

และ

$$p_d(\vec{z}_i) = \begin{cases} 2f(\vec{z}_i) & \text{ถ้า } f(\vec{z}_i) < k_2 \\ 1 & \text{ถ้า } f(\vec{z}_i) \geq sk_2 \end{cases} \quad (7.11)$$

พิจารณาการจำลองสถานการณ์การจับกลุ่มข้อมูลด้วยคอลอนีมด ยกตัวอย่างเช่นในการจับกลุ่มสี (ในงานทางด้านการประมวลผลภาพเช่นการคัดแยกสีผิวคนออกจากพื้นหลังเพื่อการประมวลผล) ในกรณีนี้เวกเตอร์ข้อมูลจะเป็นเวกเตอร์ขนาด 3×1 ที่มีองค์ประกอบเป็นค่าสีจากปริภูมิ RGB นั่นคือ $\vec{z}_i = [r_i \ g_i \ b_i]^T$ ยกตัวอย่างข้อมูลสี 4 เวกเตอร์ ประกอบไปด้วย 2 กลุ่มสี ได้แก่ น้ำเงินและขาว (หรือเทา) ดังแสดงในรูปที่ 7.3 ค่าเชิงตัวเลขของเวกเตอร์ข้อมูลสีดังกล่าวมีดังนี้




รูปที่ 7.3: ตัวอย่างการกำหนดค่าเริ่มต้นของระบบ

$$\vec{z}_1 = \begin{bmatrix} 0 \\ 51 \\ 53 \end{bmatrix} \quad \vec{z}_2 = \begin{bmatrix} 51 \\ 102 \\ 53 \end{bmatrix} \quad \vec{z}_3 = \begin{bmatrix} 204 \\ 204 \\ 204 \end{bmatrix} \quad \vec{z}_4 = \begin{bmatrix} 255 \\ 255 \\ 255 \end{bmatrix} \quad (7.12)$$


เวกเตอร์ z_1 และ z_2 เป็นเวกเตอร์ข้อมูลของกลุ่มสีน้ำเงิน (มีการปรับข้อมูลให้มีความแตกต่างกันเล็กน้อย) และเวกเตอร์ z_3 และ z_4 เป็นเวกเตอร์ข้อมูลของกลุ่มสีขาว จุดประสงค์ของการจับกลุ่มข้อมูลด้วยคอลอนีเมด คือการให้มดประดิษฐ์สามารถเคลื่อนย้ายข้อมูล แล้วนำไปวางไว้ในกลุ่มของข้อมูลที่คล้ายคลึงกันให้ได้ อัลกอริทึมการจับกลุ่มข้อมูลด้วยคอลอนีเมดสามารถสรุปได้ดังนี้

▷ อัลกอริทึมการจับกลุ่มข้อมูลด้วยคอลอนีเมด

1. กำหนดค่าเริ่มต้น (ดูรูปที่ 7.3)
 - (a) สุ่มวางข้อมูลเวกเตอร์ z_i กระจายทั่วทั้งกริด
 - (b) สุ่มวางมดประดิษฐ์ตามพื้นที่ต่างๆ ในการทดลองนี้จะใช้มดประดิษฐ์เพียงตัวเดียว เพื่อสังเกตพฤติกรรม การจับกลุ่มข้อมูลเท่านั้น (จุดสีเทามีวงกลมแดงล้อมรอบแทนตัวมดประดิษฐ์)
 - (c) กำหนดค่า k_1 k_2 α s และจำนวนรอบสูงสุดในการค้นหา t_{max} ในที่นี้ใช้ค่า $k_1 = 0.9$ และ $k_2 = 0.1$ ซึ่งมีค่าน้อยๆ ขนาดพื้นที่ในการค้นหา $s \times s$ ระบุมั่วด้วยวิธีสุ่มของวงกลมสีแดงรอบตัวมดประดิษฐ์ และในที่นี้เลือกใช้ค่า $\alpha = 441.67$ (ทำไม?)
2. สำหรับ $t = 1$ ถึง t_{max} พิจารณามดแต่ละตัว
 - (a) ถ้ามดไม่ได้หยิบเวกเตอร์ข้อมูลใดๆ ไว้ และพื้นที่รอบข้างมดมีเวกเตอร์ข้อมูล z_i
 - i. คำนวณ $f(z_i)$ และ $p_p(z_i)$
 - ii. ถ้า $U(0, 1) \leq p_p(z_i)$ ให้มดหยิบข้อมูลเวกเตอร์ z_i ไว้
 - iii. ในกรณีที่รอบๆ พื้นที่ค้นหาของมดมีข้อมูลอยู่แค่เพียงหนึ่งเวกเตอร์ กรณีนี้ค่า f จะเท่ากับศูนย์ (เนื่องจากไม่มีข้อมูลอื่นใดให้ทำการเปรียบเทียบ) ดังนั้น $p_p = \left(\frac{k_1}{k_1 + f}\right)^2 = 1$ นั่นคือมดจะหยิบข้อมูลชุดนี้ด้วยความน่าจะเป็นเท่ากับ 1 ซึ่งหมายถึงมดจะต้องหยิบข้อมูลชุดนี้แน่นอน (เนื่องจากไม่มีข้อมูลอื่นๆ ในพื้นที่รอบข้างอีกแล้ว) กล่าวคือ $p_p = 1$ จะมีค่ามากกว่าหรือเท่ากับ $U(0, 1)$ เสมอ
 - (b) มิฉะนั้นแล้ว ถ้ามดกำลังถือข้อมูลเวกเตอร์ z_i ไว้และพื้นที่รอบข้างมดว่างอยู่
 - i. คำนวณ $f(z_i)$ และ $p_d(z_i)$
 - ii. ถ้า $U(0, 1) \leq p_d(z_i)$ ให้มดปล่อยข้อมูลเวกเตอร์ z_i ไว้
 - iii. ถ้าในกรณีที่รอบๆ พื้นที่ค้นหาของมดไม่มีข้อมูลอื่นใดๆ อยู่เลย ค่า f จะเท่ากับศูนย์และค่า $p_d = \left(\frac{f}{k_2 + f}\right)^2 = 0$ ซึ่งหมายความว่าค่า p_d จะไม่มีทางมากกว่า $U(0, 1)$ เลย มดจะต้องถือข้อมูลเดินไปเรื่อยๆ นั่นคือไม่มีโอกาสในการที่จะวางข้อมูลแต่อย่างใด
 - (c) ในกรณีที่มดมีข้อมูลอยู่ แล้วเดินเข้าไปในพื้นที่ที่มีข้อมูลอื่นๆ อยู่ เราสามารถพิจารณาได้เป็นสองกรณี ดังนี้ (ดูรูปที่ 7.4 ประกอบ)



รูปที่ 7.4: มดหยิบ z_4 เดินผ่าน z_2 โดยไม่ปล่อยข้อมูล จนกระทั่งเจอ z_3 จึงทำการปล่อยข้อมูลไว้รวมกัน



รูปที่ 7.5: การเดินสำรวจผ่านกลุ่มข้อมูลของมด

- i. ถ้าข้อมูลที่มดถืออยู่ไม่มีความแตกต่างไปจากข้อมูลที่มดเดินมาเจอ ยกตัวอย่างเช่นมดถือข้อมูล $\vec{z}_4 = [255 \ 255 \ 255]^T$ อยู่แล้วเดินมาเจอกับข้อมูล $\vec{z}_3 = [204 \ 204 \ 204]^T$ พิจารณา ค่า $f(\vec{z}_4) = 1 - \frac{d(\vec{z}_4, \vec{z}_3)}{\alpha} = 1 - \frac{88.33}{\alpha}$ เราจะเห็นว่า ค่าของ α เป็นตัวที่จะปรับให้ค่าความแตกต่างระหว่างเวกเตอร์ที่กำลังเปรียบเทียบกัน (\vec{z}_4 และ \vec{z}_3) มีระดับของนัยสำคัญเกิดขึ้น ค่า α ที่มีค่าสูงกว่าจะทำให้เวกเตอร์ที่ถูกเปรียบเทียบมีความแตกต่างกันน้อยกว่า กล่าวคือค่า α ที่มากก็คือความละเอียดในการจับกลุ่มจะสูงขึ้นด้วย (มีจำนวนกลุ่มมากกว่าหรือกล่าวได้ว่าแต่ละกลุ่มมีความแตกต่างกันน้อยลง)
ถ้าค่าความแตกต่าง $d(\vec{z}_4, \vec{z}_3)$ มีค่าน้อย นั่นคือเวกเตอร์ข้อมูลที่มดถืออยู่ไม่แตกต่างกับเวกเตอร์ข้อมูลที่เจอบนกริด ค่า $f = 1 - \frac{88.33}{441.67} = 0.80$ จะมีค่ามาก และทำให้ $p_d = \left(\frac{0.80}{0.9+0.80}\right)^2 = 0.79$ ซึ่งเป็นค่าความน่าจะเป็นในการปล่อยข้อมูลมีค่าสูง นั่นคือข้อมูลทั้งคู่ควรจะต้องถูกจัดอยู่ในกลุ่มเดียวกัน โอกาสที่มดจะปล่อยข้อมูลไว้กับข้อมูลกลุ่มเดียวกันจึงต้องมีค่าสูงด้วย สังเกตว่าในกรณีนี้ เนื่องจาก f มีค่ามาก ทำให้ค่า $p_p = \left(\frac{0.1}{0.1+0.80}\right)^2 = 0.01$ มีค่าน้อย ซึ่งจะทำให้มดมีโอกาสในการหยิบข้อมูลน้อยกว่าการปล่อยข้อมูลนั่นเอง
- ii. ถ้าข้อมูลที่มดถืออยู่มีความแตกต่างไปจากข้อมูลที่มดเดินมาเจอ ยกตัวอย่างเช่นมดถือข้อมูล $\vec{z}_4 = [255 \ 255 \ 255]^T$ อยู่แล้วเดินมาเจอกับข้อมูล $\vec{z}_2 = [51 \ 102 \ 53]^T$ จะได้ว่า $f(\vec{z}_4) = 1 - \frac{d(\vec{z}_4, \vec{z}_2)}{\alpha} = 1 - \frac{325.31}{441.67} = 0.26$ ซึ่งจะมีค่าน้อยกว่าในกรณีแรก กรณีนี้ค่า $p_p = \left(\frac{0.1}{0.1+0.26}\right)^2 = 0.08$ จะมีค่ามากขึ้น แสดงว่าค่า $p_d = \left(\frac{0.26}{0.1+0.26}\right)^2 = 0.55$ จะมีค่าน้อยลง ดังนั้นมดจะมีโอกาสในการยึดถือข้อมูลนั้นต่อไปด้วยค่าความน่าจะเป็นที่สูงขึ้นกว่าการปล่อยข้อมูล
- iii. ในกรณีที่พื้นที่ค้นหาของมดมีข้อมูลเวกเตอร์มากกว่าหนึ่งข้อมูล ค่าประเมินจากฟังก์ชัน f จะบ่งบอกถึงความน่าจะเป็นของพฤติกรรมของมดว่าจะหยิบหรือปล่อยข้อมูลที่มีอยู่ในกรณีที่มดถือข้อมูลเวกเตอร์ไว้และข้อมูลดังกล่าวมีความแตกต่างไปจากข้อมูลส่วนมากในพื้นที่ค้นหาปัจจุบัน นั่นคือค่า $d(\vec{z}_i - \vec{z}_j)$ จะมีค่ามาก ทำให้ค่า $1 - \frac{d(\vec{z}_i, \vec{z}_j)}{\alpha}$ มีค่าน้อย ผลรวมของเทอมดังกล่าวทำให้ค่า f โดยรวมมีค่าน้อย ดังนั้น p_p จะมีค่ามากและ p_d จะมีค่าน้อย ดังนั้นมดจะทำการถือข้อมูลไว้ต่อไปในทางตรงกันข้าม กรณีที่ข้อมูลที่มดถือไว้และข้อมูลนั้นไม่แตกต่างไปจากข้อมูลส่วนมากในพื้นที่ค้นหาปัจจุบัน นั่นคือค่า $d(\vec{z}_i - \vec{z}_j)$ จะมีค่าน้อย ทำให้ค่า $1 - \frac{d(\vec{z}_i, \vec{z}_j)}{\alpha}$ มีค่ามาก ผลรวมของเทอมดังกล่าวทำให้ค่า f โดยรวมมีค่ามาก ดังนั้น p_p จะมีค่าน้อยและ p_d จะมีค่ามาก โอกาสที่มดจะปล่อยข้อมูลไว้กับกลุ่มข้อมูลดังกล่าวจะสูงขึ้น (ดูรูปที่ 7.5 ประกอบ)

(d) สุ่มการเดินของมดไปยังพื้นที่รอบข้างที่ไม่มดตัวอื่นอยู่ต่อไป

อัลกอริทึมการจัดกลุ่มของมดเลียนแบบพฤติกรรมทางธรรมชาติของมด ด้วยหลักการง่ายๆ แต่สามารถใช้ในการจับกลุ่มข้อมูลที่มีมิติสูง ให้อยู่ในกลุ่มบนระนาบสองมิติได้อย่างมีประสิทธิภาพ อย่างไรก็ตาม ใ้มีผู้นำเสนอแนวทางการผันแปรของอัลกอริทึมดังกล่าว เพื่อนำไปสู่ประสิทธิภาพที่ดียิ่งขึ้น อัลกอริทึมการจัดกลุ่มของมด นับเป็นแรง

บันดาลใจจากธรรมชาติที่นำมาใช้งานจริงได้อย่างน่าฉงน

7.4 การประยุกต์ใช้งาน ACO

เรียบเรียงบางส่วนจาก Ant Colony Optimization: Artificial Ants as a Computational Intelligence Technique [Dorigo et al., 2006]

ACO ถือเป็นอัลกอริทึมที่ค่อนข้างใหม่ แต่ ACO เองได้รับความสนใจจากผู้ที่เกี่ยวข้องเพิ่มขึ้นอย่างรวดเร็ว การนำเอา ACO ไปประยุกต์ใช้ในงานการหาค่าเหมาะที่สุดได้รับความนิยมอย่างมากมาย การประยุกต์ใช้งานส่วนใหญ่จะเป็นปัญหาประเภท NP-hard ที่ซึ่งอัลกอริทึมของ ACO สามารถค้นหาคำตอบที่มีคุณภาพสูงได้ การประยุกต์ใช้งานอีกประเภทหนึ่งของ ACO คือปัญหาการหาเส้นทางที่สั้นที่สุดในสภาวะแวดล้อมแบบพลวัต เช่นปัญหาการหาเส้นทางส่งข้อมูลที่สั้นที่สุดในเครือข่ายโทรคมนาคม ความสำเร็จในการนำเอา ACO มาแก้ปัญหาดังกล่าวเป็นส่วนกระตุ้นให้ผู้นำเอา ACO ไปประยุกต์ใช้จริงในงานอุตสาหกรรม เป็นการพิสูจน์ความสำเร็จของ ACO ได้เป็นอย่างดี

โดยปกติแล้วในการวัดประสิทธิภาพของกลยุทธ์การค้นหาคำตอบได้โดยนำเอากลยุทธ์นั้นๆ ไปทดสอบกับปัญหาแบบต่างๆ แล้วทำการเปรียบเทียบประสิทธิภาพกับกลยุทธ์การค้นหาคำตอบอื่นๆ ที่มีอยู่ในกรณีของ ACO ได้เริ่มทดสอบอัลกอริทึมกับปัญหาการเดินทางของเซลล์แมนหรือ TSP ดังนั้นแล้ว ปัญหาอื่นๆ ที่อยู่ในประเภท NP-hard สามารถนำมาพิจารณาใช้ด้วย ACO ได้ ที่ผ่านมามีการทดสอบ ACO กับปัญหาประเภท NP-hard มากกว่าร้อยปัญหา ปัญหาเหล่านี้ส่วนใหญ่สามารถแบ่งประเภทได้เป็นปัญหาการหาเส้นทางหรือ routing problem ตัวอย่างเช่นการกระจายสินค้า ปัญหาการกำหนดค่าหรือ assignment problem ที่ซึ่งเซตของวัตถุหรือกิจกรรม ฯลฯ จะต้องถูกกำหนดให้กับจำนวนของทรัพยากร (ตำแหน่ง ตัวแทน ฯลฯ) ภายใต้เงื่อนไขบังคับที่กำหนด ปัญหาการจัดตารางหรือ scheduling problem ที่ซึ่งจะต้องคำนึงถึงทรัพยากรจำนวนจำกัดกับการทำงานในช่วงเวลา และปัญหาเซตย่อยหรือ subset problem ที่ซึ่งคำตอบของปัญหาที่ต้องการแก้สามารถเลือกได้จากเซตย่อยของสิ่งที่มีอยู่นอกเหนือไปจากนั้นแล้ว ACO ยังประสบความสำเร็จในการนำไปประยุกต์ใช้ในงานด้านการเรียนรู้ของเครื่องจักร (machine learning) และชีวสารสนเทศศาสตร์ (bioinformatic)

ตัวอย่างการประยุกต์ใช้งาน ACO สรุปได้ดังนี้

- ปัญหาการค้นหาคำตอบ (routing)
 - TSP [Dorigo et al., 1996][Dorigo and Gambardella, 1997a][Stützle and Hoos, 2000]
 - Vehicle routing [Gambardella et al., 1999]
- ปัญหาการกำหนดค่า (assignment)
 - Sequential ordering [Gambardella and Dorigo, 2000]
 - Quadratic assignment [Stützle and Hoos, 2000][Maniezzo, 1999]
- ปัญหาการจัดตาราง (scheduling)
 - Course timetabling [Socha et al., 2002][Socha et al., 2003]
 - Graph coloring [Costa and Hertz, 1997]
 - Project scheduling [Merkle et al., 2002]
 - Total weighted tardiness [den Besten et al., 2000][Merkle and Middendorf, 2003]
- ปัญหาเซตย่อย (subset)

- Open shop [Blum, 2005]
- Set covering [Lessing et al., 2004]
- i -cardinality trees [Blum and Blesa, 2005]
- Multiple knapsack [Leguizamón and Michalewicz, 1999]
- Maximum clique [Fenet and Solnon, 2003]
- Constraint satisfaction [Solnon, 2000][Solnon, 2002]
- Classification rules [Parpinelli et al., 2002][Martens et al., 2006]
- อื่นๆ
 - Bayesian networks [de Campos et al., 2002][de Campos et al., 2002]
 - Protein folding [Shmygelska and Hoos, 2005]
 - Protein-ligand docking [Korb et al., 2006]

7.5 สรุป

ACO ได้รับการยอมรับอย่างกว้างขวางในประสิทธิภาพการทำงาน โดยเฉพาะปัญหาทางประเภท NP-hard ที่ได้มีการนำเอา ACO ไปใช้แก้ปัญหาได้สำเร็จอย่างมากมาย ACO เองยังได้รับการพิสูจน์ถึงความสามารถในการเข้าสู่ค่าตอบที่เหมาะสมที่สุดแบบวงกว้างได้ การแปรผันอัลกอริทึม ACO ที่ได้มีการนำเสนออีกอย่างมากมาย รวมไปถึงการนำไปใช้แก้ปัญหาทางวิชาการได้ด้วยความสำเร็จเป็นอย่างดี ทำให้ ACO ได้รับความสนใจนำไปประยุกต์ใช้งานจริงในอุตสาหกรรม ในขณะเดียวกัน อนาคตของ ACO ยังมีแนวโน้มที่จะได้รับความสนใจจากหลายๆ ฝ่ายอยู่ระดับหนึ่ง อันเนื่องมาจากมีนักวิจัยอีกมากมายได้กำลังพยายามนำเอา ACO ไปใช้แก้ปัญหาการหาค่าเหมาะที่สุดที่ซับซ้อนมากยิ่งขึ้น เหตุผลหนึ่งก็เพราะว่า ACO ได้แสดงให้เห็นถึงประสิทธิภาพในการใช้งานกับสภาวะแวดล้อมที่มีการเปลี่ยนแปลง (dynamic) อยู่ตลอดได้เป็นอย่างดี แนวโน้มดังกล่าวรวมไปถึงปัญหาที่มีความเพี้ยนสุ่ม (stochastic) และปัญหาที่มีวัตถุประสงค์แบบพหุคูณ (multiple objectives) นอกเหนือไปจากนั้นแล้ว ยังมีการปรากฏอยู่ของอัลกอริทึมอีกหลากหลายที่ได้แรงบันดาลใจมาจากมด (เช่นการใช้ตัวแปรแบบ stigmergy) รวมไปถึงอัลกอริทึมที่มีหลักการจากธรรมชาติที่คล้ายคลึงกับ ACO ไม่ว่าจะเป็นอัลกอริทึมที่ได้แรงบันดาลใจจากการออกหาอาหารและการทำเครื่องหมายระหว่างเส้นทาง (foraging & path marking) อัลกอริทึมที่ได้แรงบันดาลใจจากการเรียงลำดับการกกไข่ (brood sorting) อัลกอริทึมที่ได้แรงบันดาลใจจากการแบ่งงาน (division of labour) หรืออัลกอริทึมที่ได้แรงบันดาลใจจากการขนส่งแบบร่วมมือ (cooperative transport) เป็นต้น อย่างไรก็ตาม ACO ยังคงเป็นที่ยอมรับในความสำเร็จมากที่สุด และยังเป็นที่ยุติกว่า ดังนั้นแล้วทิศทางการพัฒนาและการเติบโตของ ACO ยังเป็นสิ่งที่อยู่ในความสนใจของหลายๆ ฝ่ายอยู่อย่างไม่หยุดยั้ง



โจทย์คำถาม

- 7.1. จงเขียนโปรแกรม “การทดลองสะพานคู่” โดยใช้มดสองตัวได้แก่ A_1 และ A_2 ทำการทดลองปรับค่าความยาวของสะพานทั้งสองด้วยค่าต่างๆ แล้วใช้ความสัมพันธ์จากสมการที่ 7.1 แสดงผลการเลือกเส้นทางของมด
- 7.2. จงอธิบายถึงความสำคัญของตัวประกอบการลืม (forgetting factor)
- 7.3. จงออกแบบการจัดกลุ่มข้อมูลของคอลอนีเมดในการจัดกลุ่มสำหรับใช้หาสีผิวคน (skin tone)
- 7.4. ในการจัดกลุ่มข้อมูลของคอลอนีเมด จงอธิบายว่า
 - ทำไมจำนวนกริด 2 มิติจะต้องมีขนาดมากกว่าจำนวนของมด
 - ทำไมจะต้องมีจำนวนกริดมากกว่าจำนวนข้อมูลที่ต้องการจัดกลุ่ม
- 7.5. ในการจัดกลุ่มข้อมูลของคอลอนีเมดจะมีโอกาสในการสร้างกลุ่มข้อมูลใหม่เกินความจำเป็น (เรียกว่าเกิดการพอดีเกินไปหรือ overfitting) จงอธิบายวิธีการป้องกันการเกิดกรณีดังกล่าวขึ้น





- C. Blum. Beam-aco -- hybridizing ant colony optimization with beam search: An application to open shop scheduling. *Computers & Operations Research*, 32(6):1565--1591, 2005.
- C. Blum and M. J. Blesa. New metaheuristic approaches for the edge-weighted k-cardinality tree problem. *Computer & Operations Research*, 32(6):1355--1377, 2005.
- C. Blum and M. Dorigo. The hyper-cube framework for ant colony optimization. *IEEE Transactions on Systems, Man, and Cybernetics*, 34(2):1161--1172, 2004.
- C. Blum, A. Roli, and M. Dorigo. Hc-aco: The hyper-cube framework for ant colony optimization. In *Proc. MIC'2001--Metaheuristic International Conference*, volume 2, pages 399--403, Porto, Portugal, 2001.
- E. Bonabeau, M. Dorigo, and G. Theraulaz. *Swarm Intelligence: From Natural to Artificial Systems*. Oxford University Press, 1999.
- B. Bullnheimer, R. F. Hartl, and C. Strauss. A new rank-based version of the ant system: A computational study. *Central European Journal for Operations Research and Economics*, 7(1):25--38, 1999.
- O. Cordon, I. F. de Viana, F. Herrera, and L. Moreno. A new aco model integrating evolutionary computation concepts: The best-worst ant system. In M. Dorigo et al., editor, *Proc. ANTS 2000*, pages 22--29, IRIDIA, Université Libre de Bruxelles, Belgium, 2000.
- D. Costa and A. Hertz. Ants can colour graphs. *Journal of the Operational Research Society*, 48: 295--305, 1997.
- L. M. de Campos, J. M. Fernández-Luna, J. A. Gámez, and J. M. Puerta. Ant colony optimization for learning bayesian networks. *International Journal of Approximate Reasoning*, 31(3):291--311, 2002.
- L. M. de Campos, J. A. Gámez, and J. M. Puerta. Learning bayesian networks by ant colony optimisation: Searching in the space of ordering. *Mathware and Soft Computing*, 9(2-3):251--268, 2002.
- M. L. den Besten, T. Stützle, and M. Dorigo. Ant colony optimization for the total weighted tardiness problem. In M. Schoenauer et al. ser. LNCS, editor, *Proc. PPSN-VI*, volume 1917, pages 611--620. Springer Verlag, 2000.

- J.-L. Deneubourg, S. Aron, S. Goss, and J.-M. Pasteels. The self-organizing exploratory pattern of the argentine ant. *Journal of Insect Behavior*, 3:159, 1990.
- M. Dorigo. *Optimization, Learning and Natural Algorithm (in italian)*. PhD thesis, Dipartimento di Elettronica, Politecnico di Milano, Italy, 1992.
- M. Dorigo and L. M. Gambardella. Ant colonies for the traveling salesman problem. *BioSystems*, 43 (2):73--81, 1997a.
- M. Dorigo and L. M. Gambardella. Ant colony system: A cooperative learning approach to the traveling salesman problem. *IEEE Transactions on Evolutionary Computation*, 1(1):53--66, 1997b.
- M. Dorigo, V. Maniezzo, and A. Coloni. Ant system: Optimization by a colony of cooperating agents. *IEEE Transactions on Systems, Man, and Cybernetics -- Part B*, 26(1):29--41, 1996.
- Marco Dorigo, Mauro Birattari, and Thomas Stützle. Ant colony optimization: Artificial ants as a computational intelligence technique. *IEEE Computational Intelligence Magazine*, pages 28--39, 2006.
- S. Fenet and C. Solnon. Searching for maximum cliques with ant colony optimization. In G. R. Raidl et al. ser. LNCS, editor, *Applications of Evolutionary Computing, Proc. EvoWorkshops 2003*, volume 2611, pages 236--245, 2003.
- L. M. Gambardella and M. Dorigo. Ant-q: A reinforcement learning approach to the traveling salesman problem. In A. Prieditis and S. Russell, editors, *Proc. Twelfth International Conference on Machine Learning (ML-95)*, pages 252--260. Morgan Kaufmann Publishers, 1995.
- L. M. Gambardella and M. Dorigo. Solving symmetric and asymmetric tsps by ant colonies. In T. Baeck et al., editor, *Proc. 1996 IEEE International Conference on Evolutionary Computation (ICEC'96)*, pages 622--627, Piscataway, NJ, 1996. IEEE Press.
- L. M. Gambardella and M. Dorigo. Ant colony system hybridized with a new local search for the sequential ordering problem. *INFORMS Journal on Computing*, 12(3):237--255, 2000.
- L. M. Gambardella, E. D. Taillard, and G. Agazzi. *New Ideas in Optimization*, chapter MACS-VRPTW: A multiple ant colony system for vehicle routing problems with time windows. McGraw Hill, 1999.
- S. Goss, S. Aron, J.-L. Deneubourg, and J.-M. Pasteels. Self-organized shortcuts in the argentine ant. *Naturwissenschaften*, 76:579--581, 1989.
- O. Korb, T. Stützle, and T. E. Exner. Application of ant colony optimization to structure-based drub design. In M. Dorigo et al. ser. LNCS, editor, *Proc. ANTS 2006*, volume 4150, pages 247--258. Springer Verlag, 2006.
- G. Leguizamón and Z. Michalewicz. A new version of ant system for subset problems. In *Proc. CEC'99*, pages 1459--1464, Piscataway, NJ, 1999. IEEE Press.
- L. Lessing, I. Dumitrescu, and T. Stützle. A comparison between aco algorithms for the set covering problem. In M. Dorigo et al. ser. LNCS, editor, *Proc. ANTS'2004*, volume 3172, pages 1--12. Springer Verlag, 2004.
- V. Maniezzo. Exact and approximate nondeterministic tree-search procedures for the quadratic assignment problem. *INFORMS Journal on Computing*, 11(4):358--369, 1999.

- D. Martens, M. D. Backer, R. Haesen and B. Baesens, C. Mues, and J. Vanthienen. Ant based approach to the knowledge fusion problem. In M. Doritgo et al. ser. LNCS, editor, *Proc. ANTS 2006*, volume 4150, pages 84--95. Springer Verlag, 2006.
- D. Merkle and M. Middendorf. Ant colony optimization with global pheromone evaluation for scheduling a single machine. *Applied Intelligence*, 18(1):105--111, 2003.
- D. Merkle, M. Middendorf, and H. Schmeck. Ant colony optimization for resource-constrained project scheduling. *IEEE Transactions on Evolutionary Computation*, 6(4):333--346, 2002.
- R. S. Parpinelli, H. S. Lopes, and A. A. Freitas. Data mining with an ant colony optimization algorithm. *IEEE Transactions on Evolutionary Computation*, 6(4):321--332, 2002.
- A. Shmygelska and H. H. Hoos. An ant colony optimisation algorithm for the 2d and 3d hydrophobic polar protein folding problem. *BMC Bioinformatics*, 6(30), 2005.
- K. Socha, J. Knowles, and M. Sampels. A $\mathcal{MAX} - \mathcal{MIN}$ ant system for the university timetabling problem. In M. Dorigo et al. ser. LNCS, editor, *Proceedings ANTS 2002*, volume 2463, page 1, Berlin, Germany, 2002. Springer Verlag.
- K. Socha, M. Sampels, and M. Manfrin. Ant algorithms for the university course timetabling problem with regard to the state-of-the-art. In G. R. Raidl et al. ser. LNCS, editor, *Applications of Evolutionary Computing, Proc. EvoWorkshop 2003*, volume 2611, pages 334--345. Springer Verlag, 2003.
- C. Solnon. Solving permutation constraint satisfaction problems with artificial ants. In *Proc. ECAI'2000*, pages 118--122, Amsterdam, 2000. The Netherlands: IOS Press.
- C. Solnon. Ants can solve constraint satisfaction problems. *IEEE Transactions on Evolutionary Computation*, 6(4):347--357, 2002.
- T. Stützle and H. H. Hoos. $\mathcal{MAX} - \mathcal{MIN}$ ant system. *Future Generation Computer Systems*, 16(8): 889--914, 2000.



A handwritten signature in grey ink, consisting of stylized, overlapping horizontal and vertical strokes. To the right of the signature is a circular symbol with a dot in the center, resembling an '@' symbol or a specific mark.